Линейные методы регрессии

Паточенко Евгений

НИУ ВШЭ

План занятия

- Линейная модель
- Оценка качества работы модели: функции потерь и метрики качества
- Переобучение

Линейная модель

Регрессия

Базовая модель машинного обучения и статистики, используемая для оценки зависимости между одной зависимой переменной (целевой) и одной или несколькими независимыми переменными (признаками), при этом целевая переменная — непрерывная величина

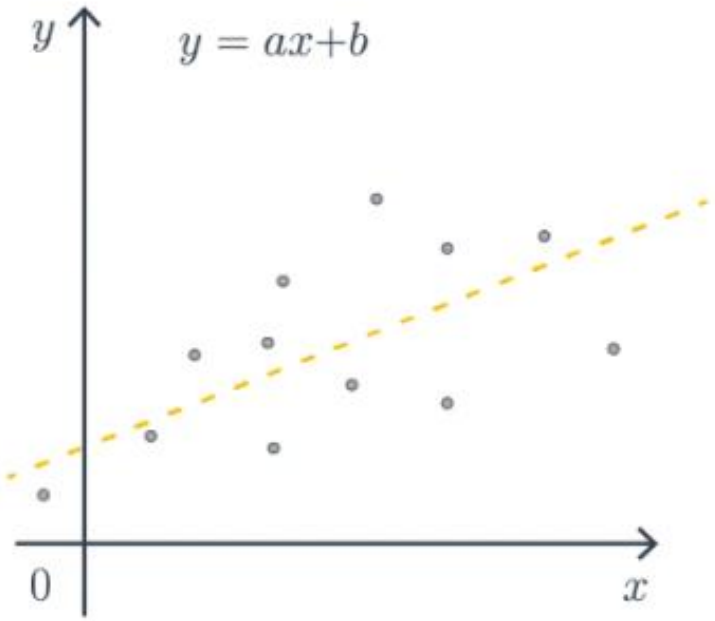

x — (единственный) признак

y — таргет

Линейная модель

Общий вид уравнения линейной регрессии

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_n x_n + \varepsilon,$$

где

- y — зависимая (целевая) переменная
- $x_1, x_2, \ldots x_n$ — независимые переменные (признаки)
- β_0 — свободный член (intercept)
- $\beta_1, \beta_2, \ldots \beta_n$ — коэффициенты (веса) модели
- ε — ошибка модели (ошибка прогноза)

Линейная модель

Общий вид уравнения линейной регрессии

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_n x_n + \varepsilon,$$

где

- y — зависимая (целевая) переменная
- $x_1, x_2, \ldots x_n$ — независимые переменные (признаки)
- β_0 — свободный член (intercept)
- $\beta_1, \beta_2, \ldots \beta_n$ — коэффициенты (веса) модели
- ε — ошибка модели (ошибка прогноза)

Сокращенная запись

$$y(x) = \beta_0 + \sum_{j=1}^{n} \beta_j x_j$$

Линейная модель

Общий вид уравнения линейной регрессии

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_n x_n + \varepsilon,$$

где

- y — зависимая (целевая) переменная
- $x_1, x_2, \ldots x_n$ — независимые переменные (признаки)
- β_0 — свободный член (intercept)
- $\beta_1, \beta_2, \ldots \beta_n$ — коэффициенты (веса) модели
- ε — ошибка модели (ошибка прогноза)

Сокращенная запись

$$y(x) = \beta_0 + \sum_{j=1}^{n} \beta_j x_j$$

Запись через скалярное произведение

$$y(x) = \beta_0 \cdot 1 + \sum_{j=1}^{n} \beta_j x_j = \sum_{j=0}^{n} \beta_j x_j = (\beta, x)$$

Линейная модель

Представление через скалярное произведение

Формула $y(x) = \beta_0 \cdot 1 + \sum_{j=1}^{n} \beta_j x_j = \sum_{j=0}^{n} \beta_j x_j = (\beta, x)$ — это не что иное, как скалярное произведение двух векторов:

- Вектора признаков объекта с фиктивной переменной $x = (1, x_1, \dots, x_n)$
- Вектора весов модели $\beta = (\beta_0, \dots, \beta_n)$

$$y(x, \beta) = \sum_{j=0}^{n} \beta_j x_j = (\beta, x)$$

Линейная модель

Пример простейшей линейной регрессии

Предположим, что в нашей компании работает очень ленивый маркетолог. Он решил простым, но модным способом защитить маркетинговый бюджет перед руководством, показав, что чем больше компания потратит на рекламу, тем большую выручку она получит.

Линейная модель

Пример простейшей линейной регрессии

Предположим, что в нашей компании работает очень ленивый маркетолог. Он решил простым, но модным способом защитить маркетинговый бюджет перед руководством, показав, что чем больше компания потратит на рекламу, тем большую выручку она получит.

Взял датасет с единственным признаком: бюджет на рекламу. Например, он будет выглядеть так

```
df = pd.read_csv('Датасет с затратами на рекламу.csv')
df
```

	ad_costs	revenue
0	8270	41794.49
1	1860	9548.03
2	6390	31977.79
3	6191	30985.12
4	6734	32950.27
...	...	...
495	5330	26892.59
496	9010	45122.65
497	7801	39861.79
498	5846	29735.07
499	7731	38556.87

500 rows × 2 columns

Линейная модель

Пример простейшей линейной регрессии

Сделал самую простую модель линейной регрессии

```
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, r2_score
```

```
X = df[['ad_costs']]
y = df['revenue']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

model = LinearRegression()
model.fit(X_train, y_train)

y_pred = model.predict(X_test)
```

Линейная модель

Пример простейшей линейной регрессии

Что значит линейной?

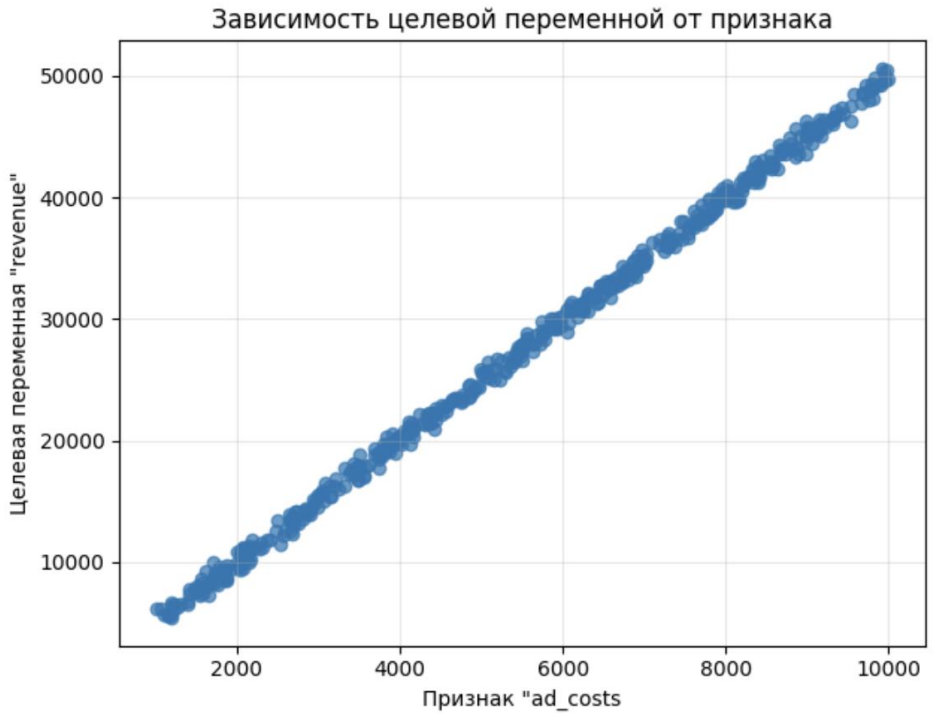

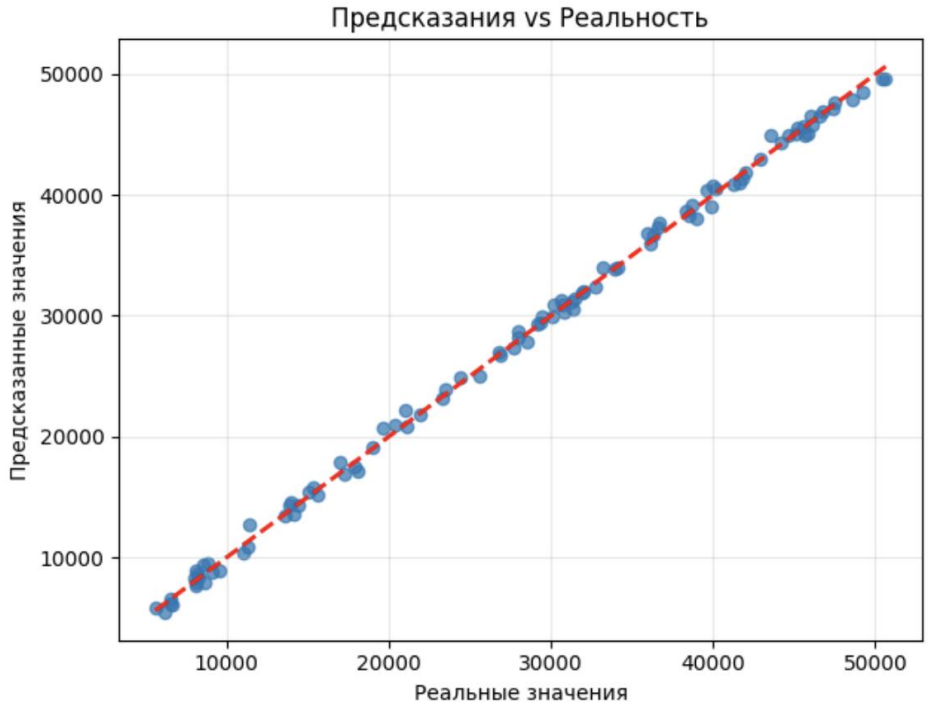

Линейная модель

Пример простейшей линейной регрессии

В конце наш маркетолог прогнал модель на трех вариантах бюджета и вывел красивые предсказания:

```
revenue = model.predict(budget_options)

result_table = pd.DataFrame({
    'budget_options': budget_options['ad_costs'].values,
    'revenue': revenue
})
result_table.round(1)
```

	budget_options	revenue
0	3000	15069.1
1	5000	25044.1
2	10000	49981.6

Линейная модель

В реальности так не бывает:)

Линейная модель

В реальности датасет будет скорее выглядеть так:

	ad_budget	marketing_spend	operational_costs	season	weekday	marketing_channel	product_category	day_of_month	month	holiday	promotion
0	16795	13546	18524	Summer	Monday	Social Media	Home	8	9	0	0
1	1860	3090	6882	Winter	Saturday	Influencer	Electronics	9	7	0	0
2	39158	17947	16113	Summer	Thursday	Search Ads	Food	13	8	0	0
3	45732	4824	15645	Winter	Wednesday	Influencer	Beauty	9	1	0	1
4	12284	11287	8012	Winter	Friday	Radio	Clothing	26	11	0	0
...	...	...	...	...	...	...	...	...	...	...	...
995	28139	9406	29272	Spring	Friday	Influencer	Books	8	5	1	1
996	12613	4646	17149	Summer	Friday	Email	Books	21	2	1	0
997	11589	12546	14150	Summer	Sunday	Radio	Home	24	2	0	0
998	14918	13111	9183	Winter	Tuesday	TV	Electronics	6	9	0	0
999	21119	13576	23632	Summer	Thursday	Email	Books	21	2	1	0

1000 rows × 19 columns

weekend	customer_rating	competitor_price	social_media_mentions	special_campaign	customer_feedback_score	delivery_time_days	revenue
1	3.0	158.757493	5.0	NaN	8.063535	NaN	17374.366924
0	3.0	151.788430	3.0	1.0	NaN	NaN	11918.449288
0	NaN	124.876416	6.0	NaN	4.429636	NaN	21210.075190
1	3.0	140.409655	6.0	NaN	7.971042	NaN	17485.981691
0	NaN	13.487588	4.0	NaN	4.756073	NaN	9667.649004
...	...	...	...	...	...	...	...
0	2.0	43.637874	NaN	NaN	4.580340	NaN	12873.641733
0	2.0	130.460146	2.0	NaN	NaN	NaN	15284.183813
0	2.0	79.189036	5.0	NaN	3.977666	NaN	14615.520120
1	4.0	171.949416	6.0	NaN	NaN	11.0	18678.260756
0	3.0	153.745005	7.0	NaN	NaN	10.0	13470.416949

Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Обработать пропуски (какие стратегии вы помните?)

Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Обработать пропуски (какие стратегии вы помните?)

Закодировать категориальные признаки

Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Обработать пропуски (какие стратегии вы помните?)

Закодировать категориальные признаки

Посмотреть распределения и зависимости, матрицу корреляций (зачем?)

Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Обработать пропуски (какие стратегии вы помните?)

Закодировать категориальные признаки

Посмотреть распределения и зависимости, матрицу корреляций (зачем?)

После этого, возможно, еще обработать данные (что еще может быть нужно?)

Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Обработать пропуски (какие стратегии вы помните?)

Закодировать категориальные признаки

Посмотреть распределения и зависимости, матрицу корреляций (зачем?)

После этого, возможно, еще обработать данные (что еще может быть нужно?)

Подробно посмотрим все эти действия на практике во второй части занятия

Линейная модель

Только после тщательной обработки данных обучаем модель

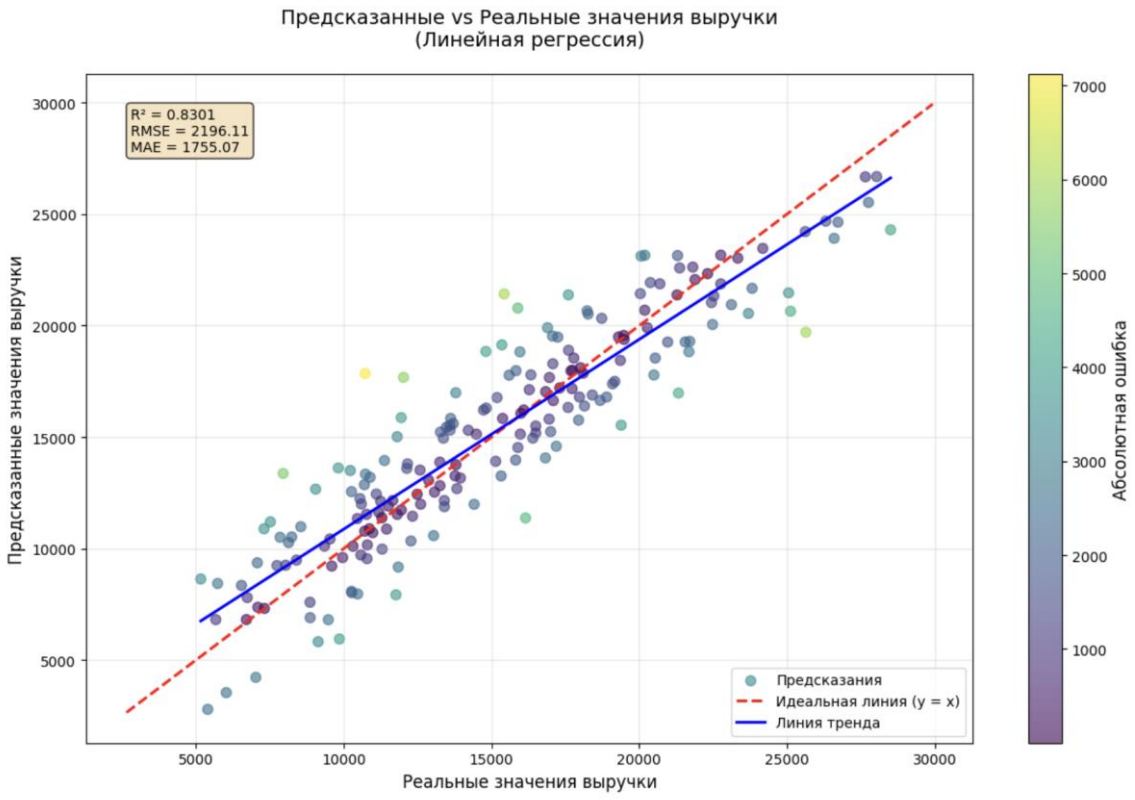

Линейная модель

Заодно оказалось, что расходы на рекламу в нашей компании вносят не такой сильный вклад в размер выручки, как того хотел бы ленивый маркетолог:)

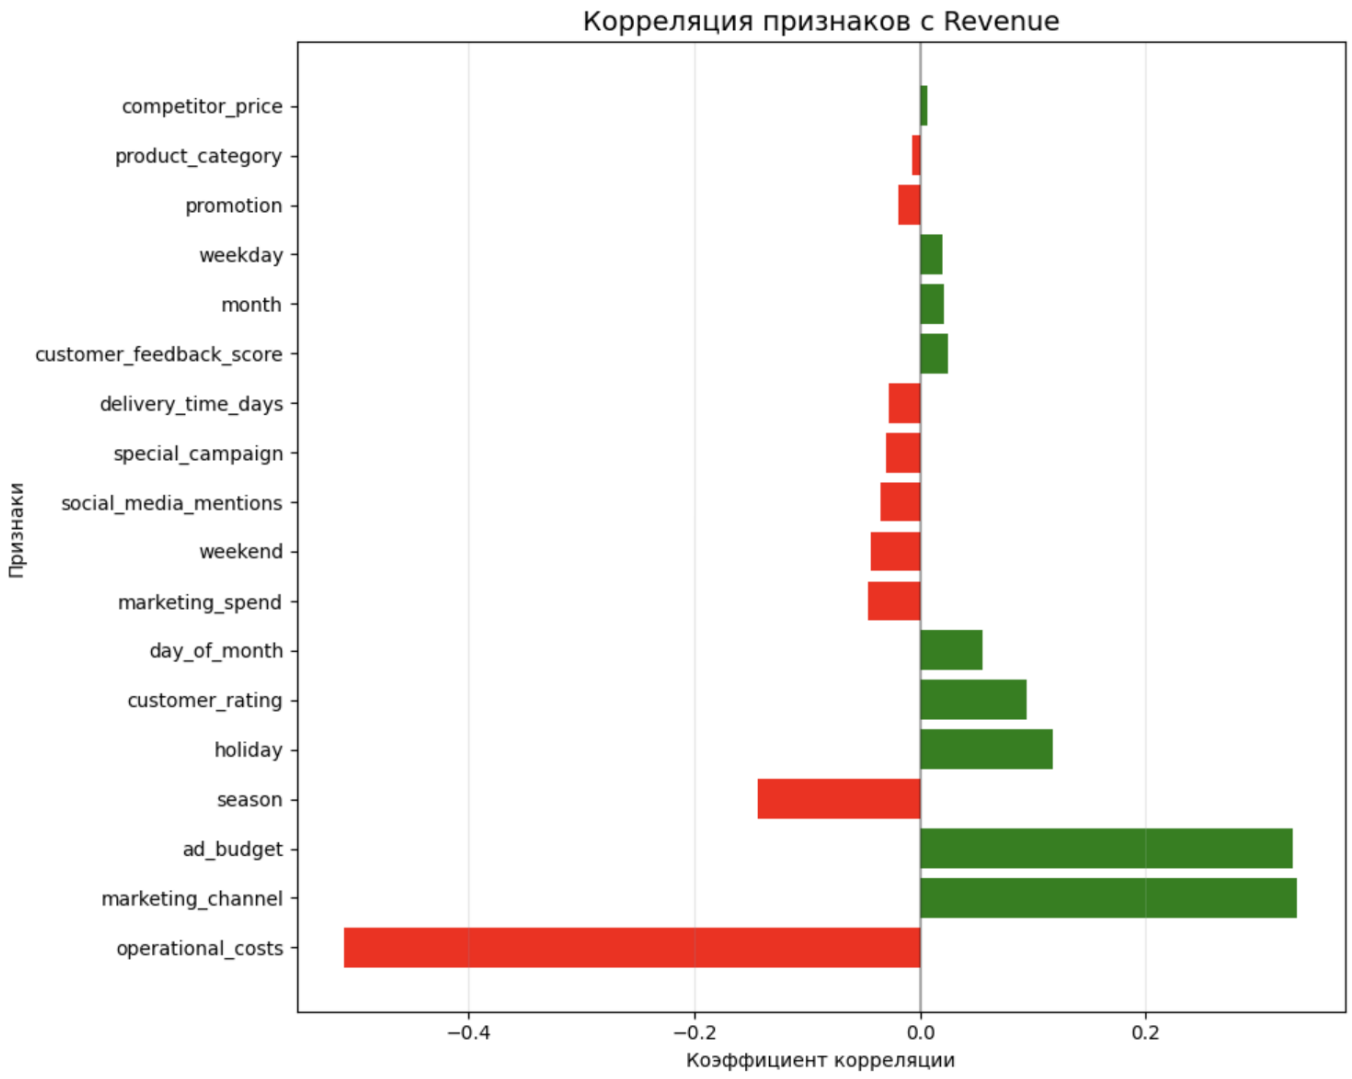

А как понять, что нашей модели можно доверять?

Оценка качества модели

Функции потерь и метрики качества (напоминание)

Функция потерь — функция, измеряющая качество работы алгоритма (ошибку предсказания модели) на объектах обучающей выборки.

Пример: MSE (среднеквадратичная ошибка, разница между предсказанным значением и истинным, возведенная в квадрат)

Метрика качества — функция, измеряющая качество работы алгоритма (ошибку предсказания модели) на данных, которые модель еще не видела, и использующаяся для сравнения моделей.

Примеры: MAE (абсолютная ошибка, модуль разницы между предсказанным значением и истинным), RMSE (корень из MSE)

Оценка качества модели

Линейная регрессия:

$$a(x) = \beta_0 + \sum_{i=1}^{n} \beta_i x_i = (\beta, x)$$

Обучение линейной регрессии — это минимизация MSE

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^{n} (a(x_i) - y_i)^2 = \frac{1}{n} \sum_{i=1}^{n} ((\beta, x_i) - y_i)^2 \longrightarrow \min_{\beta}$$

Оценка качества модели

Метод наименьших квадратов (OLS)

Цель — минимизировать сумму квадратов ошибок: $\min \beta \, \|y - X\beta\|^2$

Решение имеет аналитическую форму: $\hat{\beta} = (X^T X)^{-1} X^T y$

Оценка качества модели

Метод наименьших квадратов (OLS)

Цель — минимизировать сумму квадратов ошибок: $\min \beta \, \|y - X\beta\|^2$

Решение имеет аналитическую форму: $\hat{\beta} = (X^T X)^{-1} X^T y$

Недостатки аналитической формулы:

Оценка качества модели

Метод наименьших квадратов (OLS)

Цель — минимизировать сумму квадратов ошибок: $\min \beta \, \|y - X\beta\|^2$

Решение имеет аналитическую форму: $\hat{\beta} = (X^T X)^{-1} X^T y$

Недостатки аналитической формулы:

- Обращение матрицы — сложная операция ($O(N^3)$ от числа признаков)
- Матрица $X^T X$ может быть вырожденной или плохо обусловленной
- Если заменить среднеквадратичный функционал ошибки на другой, то скорее всего не найдем аналитическое решение

Оценка качества модели

Почему MSE? Вероятностная постановка

Даже если целевая переменная линейно зависит от признаков, идеальной модели (с вероятностью 1) не существует, то есть реальные ответы будут несильно, но отличаться от предсказаний. Поэтому мы пишем

$$y \approx (\beta, x)$$

Второй подход заключается в том, что мы объясняем неидеальность прогноза неполнотой данных, или же шумами в данных. Тогда мы пишем так:

$$y = (\beta, x) + \varepsilon,$$

где ε — это шум в данных

Оценка качества модели

Почему MSE? Вероятностная постановка

Шум в данных обычно имеет некоторое распределение. В большинстве реальных задач считается, что

$$\varepsilon \sim N(0, \sigma^2)$$

График плотности нормального распределения

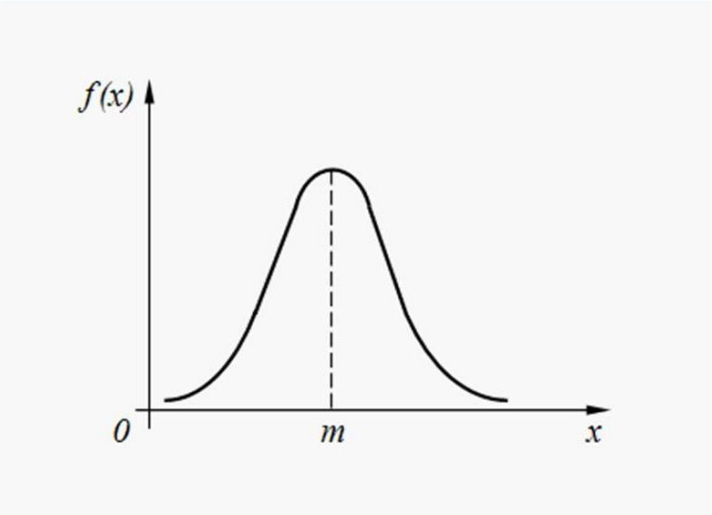

Отсюда получаем, что

$$y \sim N((\beta, x), \sigma^2)$$

Это означает, что вероятность наблюдать y при данных значениях x равна

$$p(y|x, \beta) \sim N((\beta, x), \sigma^2)$$

Оценка качества модели

Еще раз про функции потерь и метрики качества

- Функция потерь (функционал ошибки) — функция, которую минимизируют в процессе обучения модели для нахождения неизвестных параметров (весов)

- Метрика качества — функция, которую используют для оценки качества обученной модели.

Оценка качества модели

Еще раз про функции потерь и метрики качества

- Функция потерь (функционал ошибки) — функция, которую минимизируют в процессе обучения модели для нахождения неизвестных параметров (весов)
- Метрика качества — функция, которую используют для оценки качества обученной модели.

Одна и та же функция может выступать и функцией потерь, и метрикой качества — выбор зависит от задачи.

Оценка качества модели

Метрики качества

$$MSE(a, X) = \frac{1}{n}\sum_{i=1}^{n}(a(x_i)) - y_i)^2$$

Насколько метрика MSE интерпретируема?

Оценка качества модели

Метрики качества

$$MSE(a, X) = \frac{1}{n}\sum_{i=1}^{n}(a(x_i)) - y_i)^2$$

Насколько метрика MSE интерпретируема?

MSE подходит для сравнения двух моделей или для контроля качества во время обучения, но не позволяет сделать выводы о том, насколько хорошо модель решает задачу

MSE = 100 $кг^2$ — это как?:)

Оценка качества модели

Метрики качества

RMSE (root mean squared error) — корень из MSE

$$RMSE(a, X) = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(a(x_i)) - y_i)^2}$$

\+ Решает проблему единиц измерения

\− Все еще тяжело понять, насколько хорошо модель решает задачу, так как метрика не ограничена сверху

Оценка качества модели

Метрики качества

Коэффициент детерминации $\boldsymbol{R^2}$ — нормализованная MSE

$$R^2(a, X) = 1 - \frac{MSE(a,Y)}{D[Y]}, \text{где } D[Y] \text{ — дисперсия целевой переменной}$$

(+) Характеризует долю дисперсии целевой переменной, объясняемую моделью

- Чем ближе R^2 к 1, тем лучше модель объясняет данные
- Чем ближе R^2 к 0, тем ближе модель к константному решению
- Отрицательный R^2 — модель хуже константного решения и плохо объясняет данные

(−) Может быть непонятна для бизнес-заказчика

Оценка качества модели

Метрики качества

MAE (mean absolute error) — средняя абсолютная ошибка

$$MAE(a, X) = \sum_{i=0}^{n} |a(x_i) - y_i|$$

+ В отличие от MSE, которая из-за возведения в квадрат делает особый акцент на объектах с большей ошибкой, MAE менее чувствительна к выбросам

− Функция модуля не дифференцируема, сложно производить оптимизацию напрямую

Оценка качества модели

`d2_absolute_error_score`	D^2 regression score function, fraction of absolute error explained.
`d2_pinball_score`	D^2 regression score function, fraction of pinball loss explained.
`d2_tweedie_score`	D^2 regression score function, fraction of Tweedie deviance explained.
`explained_variance_score`	Explained variance regression score function.
`max_error`	The max_error metric calculates the maximum residual error.
`mean_absolute_error`	Mean absolute error regression loss.
`mean_absolute_percentage_error`	Mean absolute percentage error (MAPE) regression loss.
`mean_gamma_deviance`	Mean Gamma deviance regression loss.
`mean_pinball_loss`	Pinball loss for quantile regression.
`mean_poisson_deviance`	Mean Poisson deviance regression loss.
`mean_squared_error`	Mean squared error regression loss.
`mean_squared_log_error`	Mean squared logarithmic error regression loss.
`mean_tweedie_deviance`	Mean Tweedie deviance regression loss.
`median_absolute_error`	Median absolute error regression loss.
`r2_score`	R^2 (coefficient of determination) regression score function.
`root_mean_squared_error`	Root mean squared error regression loss.
`root_mean_squared_log_error`	Root mean squared logarithmic error regression loss.

... и это только для линейной регрессии

Метрики реализованы в библиотеке scikit-learn

Переобучение

Переобучение (overfitting) — явление, при котором качество модели на новых данных сильно хуже, чем на обучающей выборке

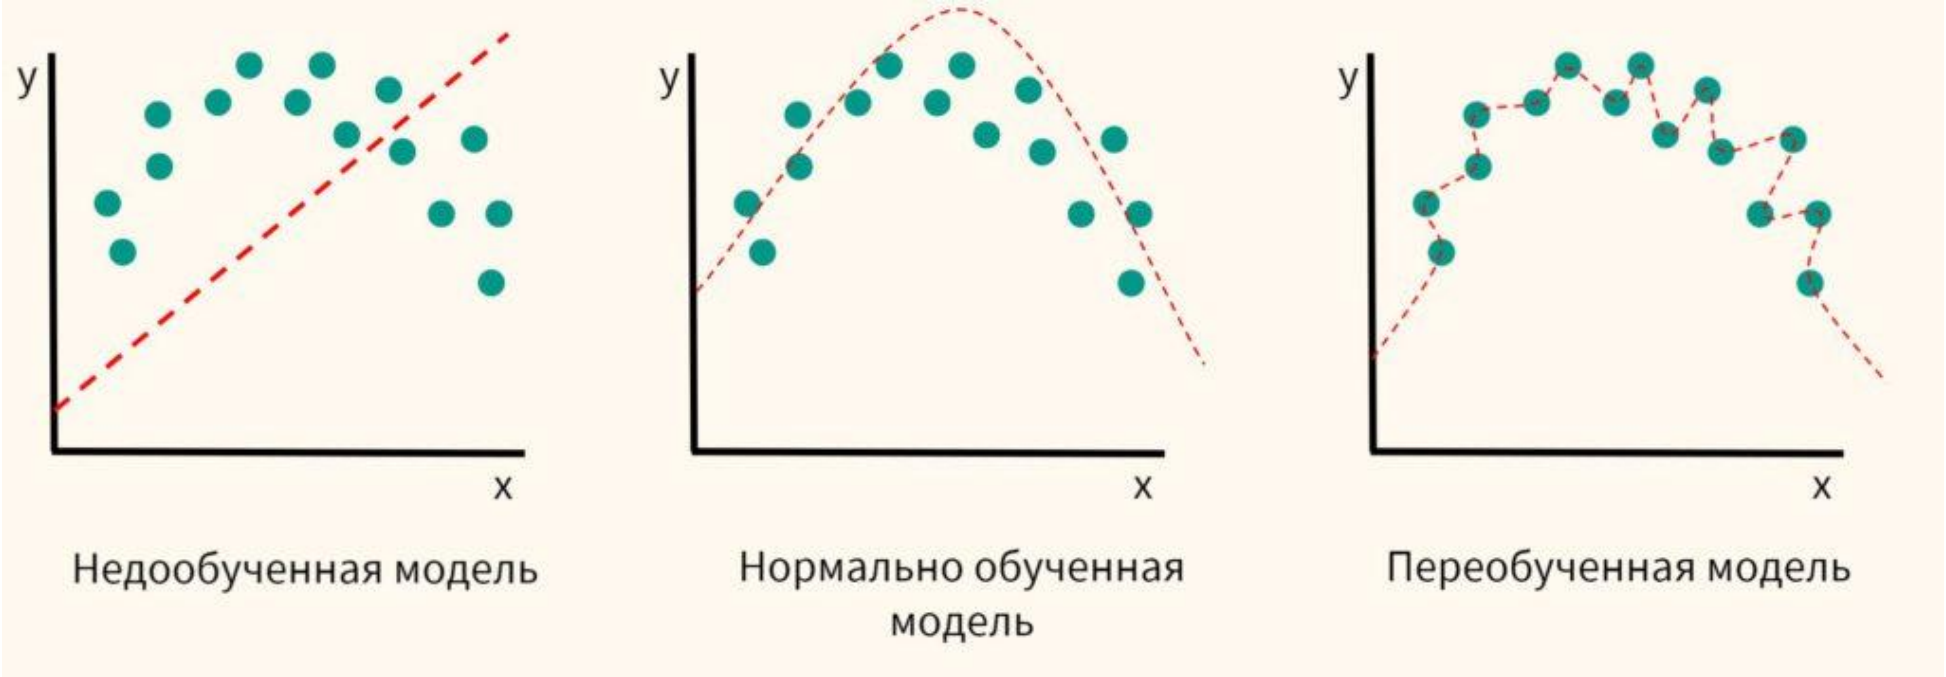

Переобучение

Причины переобучения

Переобучение

Причины переобучения

- Переобучение есть всегда, когда есть оптимизация параметров по конечной (заведомо неполной) выборке

Переобучение

Причины переобучения

- Переобучение есть всегда, когда есть оптимизация параметров по конечной (заведомо неполной) выборке
- При небольшом количестве объектов в датасете выше вероятность того, что модель запомнит обучающие данные, а не будет обобщать их на новые, ранее невиданные экземпляры

Переобучение

Причины переобучения

- Переобучение есть всегда, когда есть оптимизация параметров по конечной (заведомо неполной) выборке
- При небольшом количестве объектов в датасете выше вероятность того, что модель запомнит обучающие данные, а не будет обобщать их на новые, ранее невиданные экземпляры
- Избыточная сложность модели (большое количество весов). В этом случае лишние степени свободы в модели «тратятся» на чрезмерно точную подгонку под обучающую выборку

Переобучение

Причины переобучения

- Переобучение есть всегда, когда есть оптимизация параметров по конечной (заведомо неполной) выборке
- При небольшом количестве объектов в датасете выше вероятность того, что модель запомнит обучающие данные, а не будет обобщать их на новые, ранее невиданные экземпляры
- Избыточная сложность модели (большое количество весов). В этом случае лишние степени свободы в модели «тратятся» на чрезмерно точную подгонку под обучающую выборку

С переобучением можно и нужно бороться! Как это сделать — рассмотрим на следующих занятиях.