# Линейные методы регрессии

Паточенко Евгений

НИУ ВШЭ

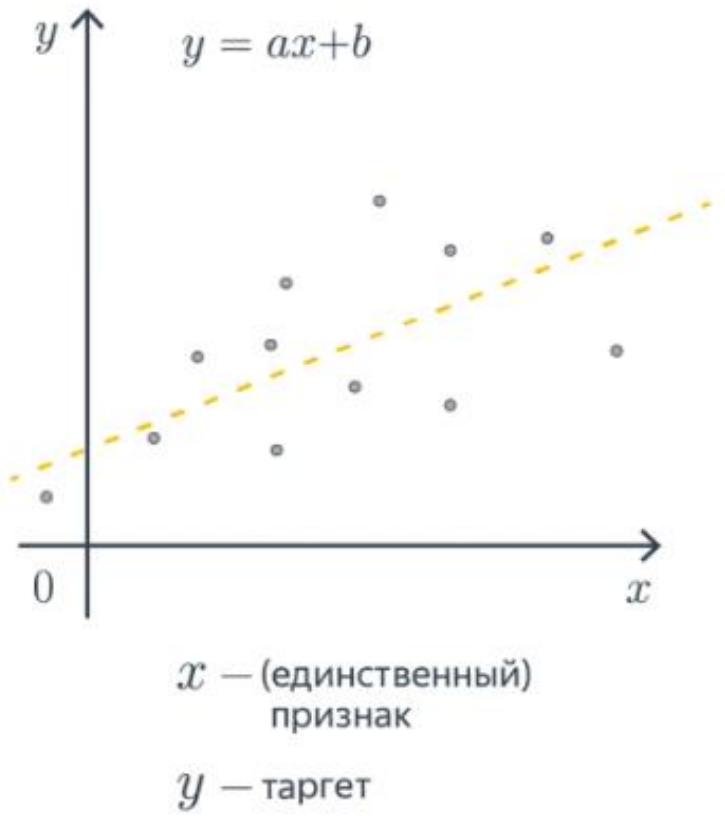
# План занятия

- Линейная модель
- Оценка качества работы модели: функции потерь и метрики качества
- Переобучение

# Линейная модель

*Регрессия*

Базовая модель машинного обучения и статистики, используемая для оценки зависимости между одной зависимой переменной (целевой) и одной или несколькими независимыми переменными (признаками), при этом целевая переменная — непрерывная величина



# Линейная модель

**Общий вид уравнения линейной регрессии**

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_d x_d + \varepsilon,$$

где $d$ — число признаков:

- $y$ — зависимая (целевая) переменная
- $x_1, x_2, \ldots x_d$ — независимые переменные (признаки)
- $\beta_0$ — свободный член (intercept)
- $\beta_1, \beta_2, \ldots \beta_d$ — коэффициенты (веса) модели
- $\varepsilon$ — ошибка модели (ошибка прогноза)

# Линейная модель

**Общий вид уравнения линейной регрессии**

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_d x_d + \varepsilon,$$

где $d$ — число признаков:

- $y$ — зависимая (целевая) переменная
- $x_1, x_2, \ldots x_d$ — независимые переменные (признаки)
- $\beta_0$ — свободный член (intercept)
- $\beta_1, \beta_2, \ldots \beta_d$ — коэффициенты (веса) модели
- $\varepsilon$ — ошибка модели (ошибка прогноза)

**Сокращенная запись предсказания**

$$\hat{y}(x) = \beta_0 + \sum_{j=1}^{d} \beta_j x_j$$

Здесь $\hat{y}$ — предсказание модели без ошибки:
$y = \hat{y} + \varepsilon$

# Линейная модель

**Общий вид уравнения линейной регрессии**

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_d x_d + \varepsilon,$$

где $d$ — число признаков:

- $y$ — зависимая (целевая) переменная
- $x_1, x_2, \ldots x_d$ — независимые переменные (признаки)
- $\beta_0$ — свободный член (intercept)
- $\beta_1, \beta_2, \ldots \beta_d$ — коэффициенты (веса) модели
- $\varepsilon$ — ошибка модели (ошибка прогноза)

**Сокращенная запись предсказания**

$$\hat{y}(x) = \beta_0 + \sum_{j=1}^{d} \beta_j x_j$$

Здесь $\hat{y}$ — предсказание модели без ошибки:
$y = \hat{y} + \varepsilon$

**Запись через скалярное произведение**

$$\hat{y}(x) = \beta_0 \cdot 1 + \sum_{j=1}^{d} \beta_j x_j = \sum_{j=0}^{d} \beta_j x_j = (\beta, x)$$

где $x_0 = 1$ — фиктивный признак

# Линейная модель

*Представление через скалярное произведение*

Формула $\hat{y}(x) = \beta_0 \cdot 1 + \sum_{j=1}^{d} \beta_j x_j = \sum_{j=0}^{d} \beta_j x_j = (\beta, x)$ — это не что иное, как скалярное произведение двух векторов:

- Вектора признаков объекта с фиктивной переменной $x = (1, x_1, \dots, x_d)$
- Вектора весов модели $\beta = (\beta_0, \dots, \beta_d)$

$$\hat{y}(x) = \sum_{j=0}^{d} \beta_j x_j = (\beta, x) = \beta^T x$$

# Линейная модель

*Пример простейшей линейной регрессии*

Предположим, что мы хотим оценить стоимость квартиры в Москве и Подмосковье по одному признаку — площади.

# Линейная модель

*Пример простейшей линейной регрессии*

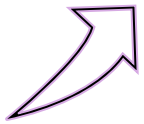
Предположим, что мы хотим оценить стоимость квартиры в Москве и Подмосковье по одному признаку — площади.

Возьмем датасет с единственным признаком: площадь. Например, он будет выглядеть так

```
df = pd.read_csv('flats.csv')
df[['Area', 'Price']]
```

| | Area | Price |
|---|---|---|
| 0 | 30.60 | 6300000.0 |
| 1 | 49.20 | 9000000.0 |
| 2 | 44.70 | 11090000.0 |
| 3 | 35.10 | 8300000.0 |
| 4 | 37.70 | 6450000.0 |
| ... | ... | ... |
| 22671 | 31.75 | 4768792.0 |
| 22672 | 31.60 | 5900000.0 |
| 22673 | 18.00 | 3700000.0 |
| 22674 | 36.39 | 5768869.0 |
| 22675 | 56.13 | 6839157.0 |

22676 rows × 2 columns



# Линейная модель

*Пример простейшей линейной регрессии*

Обучим простую модель линейной регрессии

```
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, r2_score

X = df[['Area']]
y = df['Price']

# 75% объектов — обучение (train), 25% — проверка (test)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42)

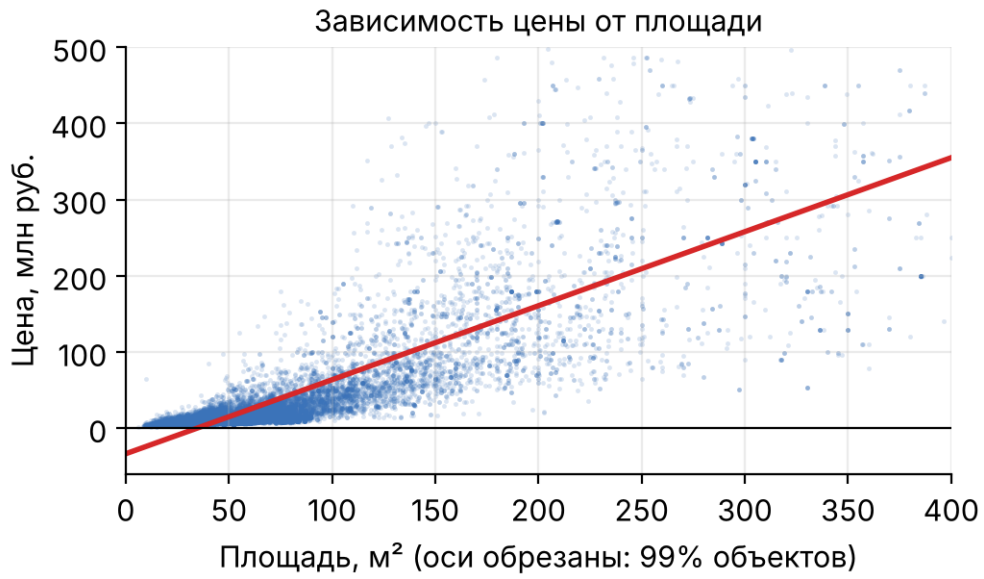
model = LinearRegression()
model.fit(X_train, y_train)

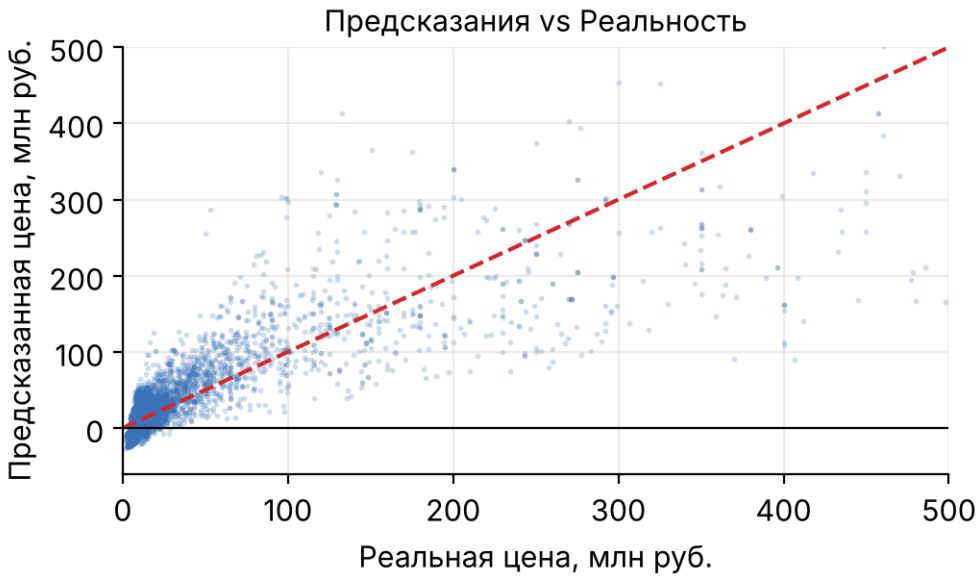
y_pred = model.predict(X_test)
```

# Линейная модель

*Пример простейшей линейной регрессии*

Цена = β0 + β1·площадь



# Линейная модель

*Пример простейшей линейной регрессии*

Предскажем цену квартир площадью 30, 50 и 100 м²:

```
area_options = pd.DataFrame({'Area': [30, 50, 100]})
price = model.predict(area_options)

result_table = pd.DataFrame({'Area': area_options['Area'].values,
                             'Price': price})
result_table.round(1)
```

| | Area | Price |
|---|---|---|
| 0 | 30 | -4652699.8 |
| 1 | 50 | 14791543.0 |
| 2 | 100 | 63402150.0 |

# Линейная модель

*Цена квартиры в 30 м² получилась отрицательной. Что-то здесь не так*

# Линейная модель

Реальный датасет устроен сложнее: есть метро, этаж, ремонт и другие признаки. Вот как выглядит исходный датасет:

| Price | Apartment type | Metro station | Minutes to metro | Region | Number of rooms | Area | Living area | Kitchen area | Floor | Number of floors | Renovation |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 6300000.0 | Secondary | Опалиха | 6 | Moscow region | 1 | 30.6 | 11.1 | 8.5 | 25 | 25 | Cosmetic |
| 9000000.0 | Secondary | Павшино | 2 | Moscow region | 1 | 49.2 | 20 | 10 | 6 | 15 | European-style renovation |
| 11090000.0 | Secondary | Мякинино | 14 | Moscow region | 1 | 44.7 | 16.2 | 13.1 | 10 | 25 | Cosmetic |
| 8300000.0 | Secondary | Строгино | 8 | Moscow region | 1 | 35.1 | 16 | 11 | 12 | 33 | European-style renovation |
| 6450000.0 | Secondary | Опалиха | 6 | Moscow region | 1 | 37.7 | 15.2 | 4 | 5 | 5 | Without renovation |

22676 строк × 12 столбцов: целевая переменная Price, 7 числовых и 4 категориальных признака

# Линейная модель

Что нам нужно сделать прежде чем обучить модель?

# Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Обработать пропуски (какие стратегии вы помните?)

# Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Обработать пропуски (какие стратегии вы помните?)

Закодировать категориальные признаки

# Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Обработать пропуски (какие стратегии вы помните?)

Закодировать категориальные признаки

Посмотреть распределения и зависимости, матрицу корреляций (зачем?)

# Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Обработать пропуски (какие стратегии вы помните?)

Закодировать категориальные признаки

Посмотреть распределения и зависимости, матрицу корреляций (зачем?)

После этого, возможно, еще обработать данные (что еще может быть нужно?)

# Линейная модель

Что нам нужно сделать прежде чем обучить модель?

Обработать пропуски (какие стратегии вы помните?)

Закодировать категориальные признаки

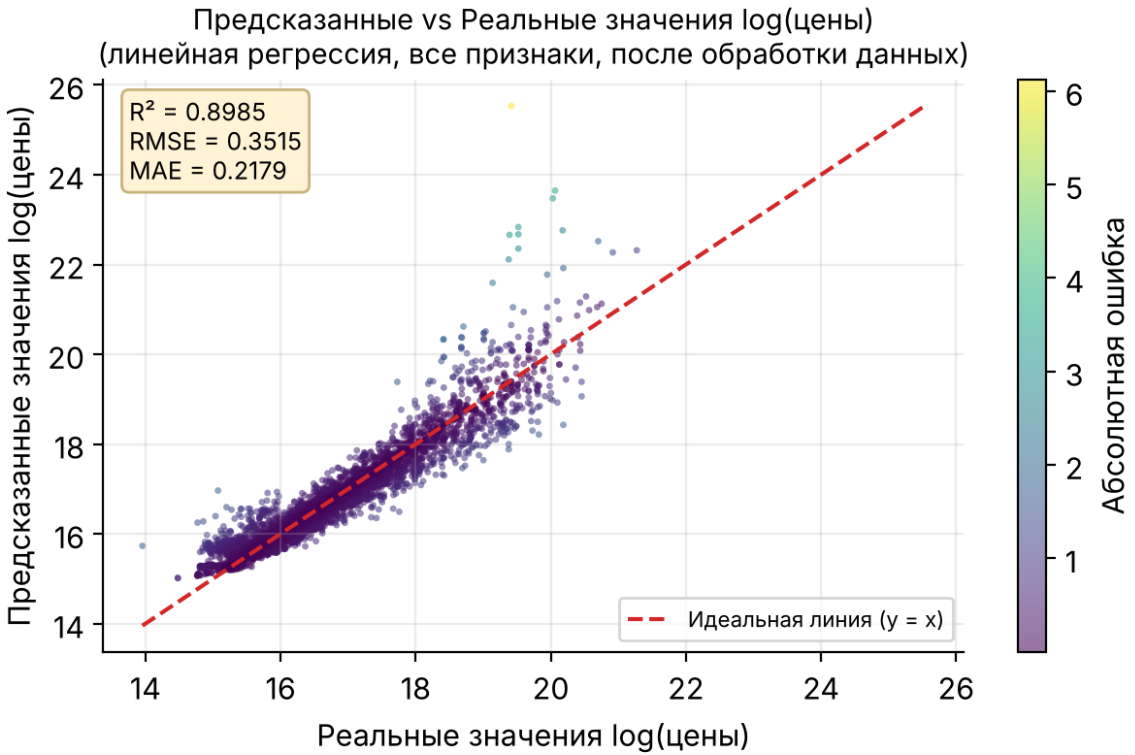
Посмотреть распределения и зависимости, матрицу корреляций (зачем?)

После этого, возможно, еще обработать данные (что еще может быть нужно?)

Подробно посмотрим все эти действия на практике во второй части занятия

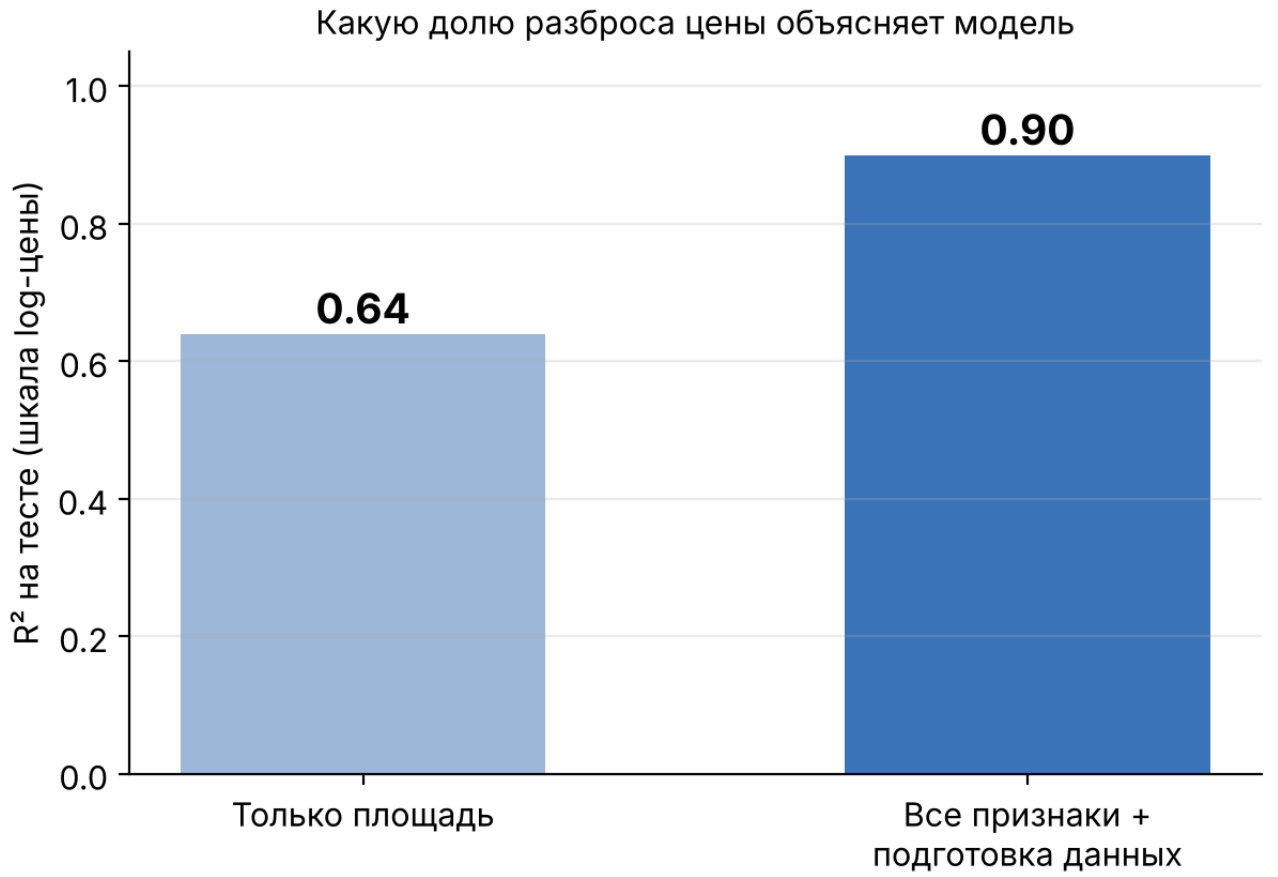
# Линейная модель

Только после тщательной обработки данных обучаем модель на всех признаках



# Линейная модель

Одна площадь объясняет около 64% разброса цены. Со всеми признаками и подготовкой данных — около 90%.



А как понять, что нашей модели можно доверять?

# Оценка качества модели

*Функции потерь и метрики качества (напоминание)*

**Функция потерь** — функция, измеряющая качество работы алгоритма (ошибку предсказания модели) на объектах обучающей выборки.

Пример: MSE (среднеквадратичная ошибка: среднее значение квадрата разницы между предсказанным и истинным значением)

**Метрика качества** — функция, измеряющая качество работы алгоритма (ошибку предсказания модели) на данных, которые модель еще не видела, и использующаяся для сравнения моделей.

Примеры: MAE (средняя абсолютная ошибка: среднее значение модуля разницы между предсказанным и истинным значением), RMSE (корень из MSE)

# Оценка качества модели

***Линейная регрессия:***

$$a(x) = \hat{y}(x) = \beta_0 + \sum_{j=1}^{d} \beta_j x_j = (\beta, x)$$

Здесь $n$ — число объектов ($i$ — номер объекта), $d$ — число признаков ($j$ — номер признака), $X$ — матрица «объекты × признаки» размера $n \times (d+1)$ (первый столбец — единицы), $y$ — вектор ответов

***Обучение линейной регрессии — это минимизация MSE***

$$Q(a, X) = \frac{1}{n} \sum_{i=1}^{n} (a(x_i) - y_i)^2 = \frac{1}{n} \sum_{i=1}^{n} \big((\beta, x_i) - y_i\big)^2 \to \min_{\beta}$$

# Оценка качества модели

***Метод наименьших квадратов (OLS)***

Цель — минимизировать сумму квадратов ошибок: $\hat{\beta} = \text{argmin}_{\beta} \parallel y - X\beta \parallel^2$

Решение имеет аналитическую форму: $\hat{\beta} = (X^T X)^{-1} X^T y$

# Оценка качества модели

***Метод наименьших квадратов (OLS)***

Цель — минимизировать сумму квадратов ошибок: $\hat{\beta} = \text{argmin}_{\beta} \parallel y - X\beta \parallel^2$

Решение имеет аналитическую форму: $\hat{\beta} = (X^T X)^{-1} X^T y$

Недостатки аналитической формулы:

# Оценка качества модели

***Метод наименьших квадратов (OLS)***

Цель — минимизировать сумму квадратов ошибок: $\hat{\beta} = \text{argmin}_{\beta} \| y - X\beta \|^2$

Решение имеет аналитическую форму: $\hat{\beta} = (X^T X)^{-1} X^T y$

Недостатки аналитической формулы:

- Обращение матрицы — сложная операция ($O(d^3)$) от числа признаков
- Матрица $X^T X$ может быть вырожденной или плохо обусловленной
- Если заменить среднеквадратичный функционал ошибки на другой, то скорее всего не найдем аналитическое решение

# Оценка качества модели

***Метод наименьших квадратов: откуда берется формула***

Сумма квадратов ошибок — это MSE, умноженная на $n$, поэтому минимизировать ее — то же самое:

$$\| y - X\beta \|^2 = \sum_{i=1}^{n} \left(y_i - (\beta, x_i)\right)^2 = n \cdot \text{MSE}$$

В точке минимума градиент равен нулю:

$$\nabla_\beta \| y - X\beta \|^2 = -2X^T(y - X\beta) = 0 \;\Rightarrow\; X^T X\beta = X^T y$$

Это нормальные уравнения. Если матрица $X^T X$ обратима, их решение:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

Здесь $X$ — матрица $n \times (d+1)$ с единичным столбцом, $y$ — вектор ответов, $\beta$ — вектор из $d+1$ весов.

# Оценка качества модели

***Когда формула не работает: вырожденность и мультиколлинеарность***

Матрица $X^T X$ обратима, если столбцы $X$ линейно независимы. Пример нарушения: в датасет попали площадь в м² и в кв. футах — признаки пропорциональны, матрица вырождена, формула неприменима.

Чаще признаки дублируют друг друга не точно, а почти: площадь и жилая площадь (корреляция 0,91). Матрица обратима, но плохо обусловлена, и веса становятся неустойчивыми.

На квартирах: по одной площади вес равен 0,96 млн ₽ за м². Добавили жилую площадь — вес площади стал 1,03, а вес жилой площади получился отрицательным (−0,13), хотя связь с ценой положительная.

Стоимость: построить $X^T X$ — $O(nd^2)$, обратить — $O(d^3)$. На больших данных вместо формулы используют градиентный спуск.

# Оценка качества модели

***Почему MSE? Вероятностная постановка***

Даже если целевая переменная линейно зависит от признаков, идеальной модели (с вероятностью 1) не существует, то есть реальные ответы будут несильно, но отличаться от предсказаний. Поэтому мы пишем

$$y \approx (\beta, x)$$

Второй подход заключается в том, что мы объясняем неидеальность прогноза неполнотой данных, или же шумами в данных. Тогда мы пишем так:

$$y = (\beta, x) + \varepsilon,$$

где $\varepsilon$ — это шум в данных

# Оценка качества модели

***Почему MSE? Вероятностная постановка***

Шум складывается из множества мелких независимых факторов, поэтому его обычно считают нормальным с постоянной дисперсией:

$$\varepsilon \sim N(0, \sigma^2)$$

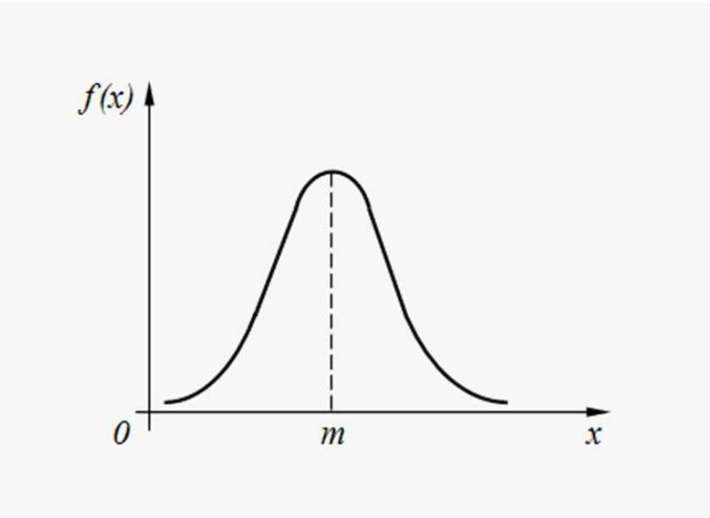
Отсюда получаем, что

$$y \mid x \sim N\big((\beta, x), \sigma^2\big)$$

Это означает, что плотность вероятности $y$ при данных значениях $x$ равна

$$p(y \mid x, \beta) = N(y \mid (\beta, x), \sigma^2)$$

*График плотности нормального распределения*



# Оценка качества модели

***Метод максимального правдоподобия***

Мы хотим подобрать такой вектор $\beta$, при котором правдоподобие наблюдаемой выборки (вероятность увидеть именно такие $y$ при данных $X$) максимально

$$p(y \mid X, \beta) \to \max_{\beta}$$

Величина $p(y \mid X, \beta)$ называется функцией правдоподобия (или правдоподобием) выборки; при фиксированных данных это функция от $\beta$

# Оценка качества модели

***Метод максимального правдоподобия***

Модель данных с независимым гауссовским шумом:

$$y_i = (\beta, x_i) + \varepsilon_i,\ \varepsilon_i \sim N(0, \sigma^2),\ i = 1, \dots, n$$

# Оценка качества модели

***Метод максимального правдоподобия***

Модель данных с независимым гауссовским шумом:

$$y_i = (\beta, x_i) + \varepsilon_i,\ \varepsilon_i \sim N(0, \sigma^2),\ i = 1, \dots, n$$

Тогда

$$y_i \sim N\big((\beta, x_i), \sigma^2\big),\ i = 1, \dots, n$$

# Оценка качества модели

***Метод максимального правдоподобия***

Модель данных с независимым гауссовским шумом:

$$y_i = (\beta, x_i) + \varepsilon_i,\ \varepsilon_i \sim N(0, \sigma^2),\ i = 1, \dots, n$$

Тогда

$$y_i \sim N\big((\beta, x_i), \sigma^2\big),\ i = 1, \dots, n$$

Метод максимального правдоподобия (ММП):

$$L(y_1, \dots, y_n \mid \beta) = \prod_{i=1}^{n} \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{\big(y_i - (\beta, x_i)\big)^2}{2\sigma^2}\right) \to \max_{\beta}$$

# Оценка качества модели

***Метод максимального правдоподобия***

Модель данных с независимым гауссовским шумом:

$$y_i = (\beta, x_i) + \varepsilon_i,\ \varepsilon_i \sim N(0, \sigma^2),\ i = 1, \dots, n$$

Тогда

$$y_i \sim N\big((\beta, x_i), \sigma^2\big),\ i = 1, \dots, n$$

Метод максимального правдоподобия (ММП):

$$L(y_1, \dots, y_n \mid \beta) = \prod_{i=1}^{n} \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{\big(y_i - (\beta, x_i)\big)^2}{2\sigma^2}\right) \to \max_{\beta}$$

$$-\ln L(y_1, \dots, y_n \mid \beta) = \text{const} + \frac{1}{2\sigma^2} \sum_{i=1}^{n} \big(y_i - (\beta, x_i)\big)^2 \to \min_{\beta}$$

Логарифм монотонен: произведение превращается в сумму, а минус меняет max на min

# Оценка качества модели

***Метод максимального правдоподобия***

При гауссовском шуме ММП совпадает с МНК; при лапласовском получится MAE

Модель данных с независимым гауссовским шумом:

$$y_i = (\beta, x_i) + \varepsilon_i,\ \varepsilon_i \sim N(0, \sigma^2),\ i = 1, \dots, n$$

Тогда

$$y_i \sim N\big((\beta, x_i), \sigma^2\big),\ i = 1, \dots, n$$

Метод максимального правдоподобия (ММП):

$$L(y_1, \dots, y_n \mid \beta) = \prod_{i=1}^{n} \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{\big(y_i - (\beta, x_i)\big)^2}{2\sigma^2}\right) \to \max_{\beta}$$

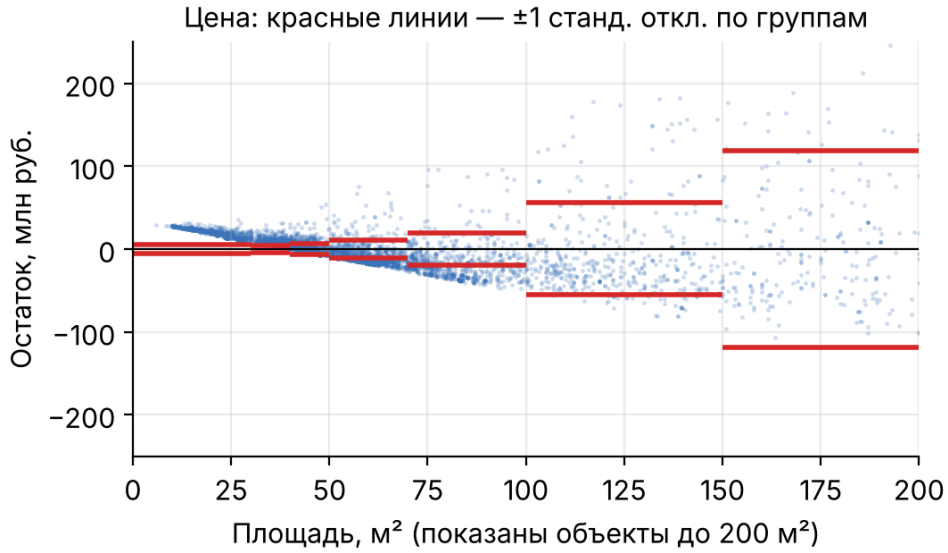
$$-\ln L(y_1, \dots, y_n \mid \beta) = \text{const} + \frac{1}{2\sigma^2} \sum_{i=1}^{n} \big(y_i - (\beta, x_i)\big)^2 \to \min_{\beta}$$

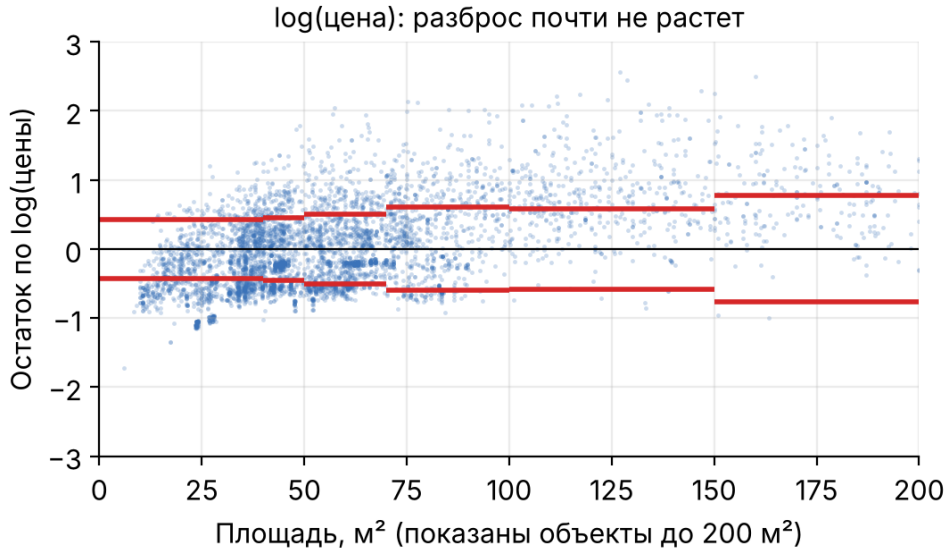
Логарифм монотонен: произведение превращается в сумму, а минус меняет max на min

# Оценка качества модели

***Выполняются ли предположения на наших данных?***

ММП вывели в предположении, что дисперсия шума одна и та же для всех объектов. Смотрим на остатки модели только по площади (тест): на цене в рублях разброс растет с площадью от 5 до 119 млн ₽, то есть в 22 раза; на логарифме цены — от 0,43 до 0,77.




**Поэтому в семинаре мы предсказываем не цену, а log(цены).**

# Оценка качества модели

***Еще раз про функции потерь и метрики качества***

- Функция потерь (функционал ошибки) — функция, которую минимизируют в процессе обучения модели для нахождения неизвестных параметров (весов)

- Метрика качества — функция, которую используют для оценки качества обученной модели.

# Оценка качества модели

***Еще раз про функции потерь и метрики качества***

- Функция потерь (функционал ошибки) — функция, которую минимизируют в процессе обучения модели для нахождения неизвестных параметров (весов)

- Метрика качества — функция, которую используют для оценки качества обученной модели.

Одна и та же функция может выступать и функцией потерь, и метрикой качества — выбор зависит от задачи (и от выборки: на обучающей — потери, на тестовой — метрика).

# Оценка качества модели

***Метрики качества***

$$\mathrm{MSE}(a, X) = \frac{1}{n}\sum_{i=1}^{n}(a(x_i) - y_i)^2$$

Насколько метрика MSE интерпретируема?

# Оценка качества модели

***Метрики качества***

$$\mathrm{MSE}(a, X) = \frac{1}{n}\sum_{i=1}^{n}(a(x_i) - y_i)^2$$

Насколько метрика MSE интерпретируема?

MSE подходит для сравнения двух моделей или для контроля качества во время обучения, но не позволяет сделать выводы о том, насколько хорошо модель решает задачу

MSE = 100 $\text{кг}^2$ — это как?:)

# Оценка качества модели

***Метрики качества***

**RMSE (root mean squared error)** — корень из MSE

$$\mathrm{RMSE}(a, X) = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(a(x_i) - y_i)^2}$$

⊕ Решает проблему единиц измерения

⊖ Все еще тяжело понять, насколько хорошо модель решает задачу, так как метрика не ограничена сверху

# Оценка качества модели

*Метрики качества*

**Коэффициент детерминации $\mathbf{R^2}$ — нормализованная MSE**

$$R^2(a, X) = 1 - \frac{\text{MSE}(a,X)}{D[y]}$$, где $D[y]$ — дисперсия ответов (MSE константы $\bar{y}$)

⊕ Характеризует долю дисперсии целевой переменной, объясняемую моделью

- Чем ближе $R^2$ к 1, тем лучше модель объясняет данные
- Чем ближе $R^2$ к 0, тем ближе модель к константному решению
- Отрицательный $R^2$ — модель хуже константного решения (на тесте так бывает)

⊖ Может быть непонятна для бизнес-заказчика

# Оценка качества модели

***Метрики качества***

**MAE (mean absolute error)** — средняя абсолютная ошибка

$$\mathrm{MAE}(a, X) = \frac{1}{n}\sum_{i=1}^{n}|a(x_i) - y_i|$$

⊕ Единицы — как у цены. Не раздувает большие ошибки квадратом, поэтому менее чувствительна к выбросам (лучшая константа для MAE — медиана, для MSE — среднее)

⊖ Функция модуля не дифференцируема в нуле, сложно производить оптимизацию напрямую

# Оценка качества модели

***Метрики на квартирах: модель только по площади, тестовая выборка***

| | $R^2$ | RMSE | MAE |
|---|---|---|---|
| Прогноз = среднее по обучающей выборке | 0,00 | 80,7 млн ₽ | 39,5 млн ₽ |
| Линейная модель по площади | 0,63 | 49,4 млн ₽ | 22,7 млн ₽ |

**RMSE вдвое больше MAE:** несколько очень дорогих квартир сильно раздувают квадратичную ошибку. Если убрать 1% самых дорогих объектов теста, получится RMSE 35,2 и MAE 19,9 млн ₽.

**$R^2$ = 0,63 выглядит прилично,** но та же модель предсказывает отрицательную цену для маленьких квартир. Ни одна метрика не заменяет взгляд на график остатков.

# Оценка качества модели

| | |
|---|---|
| `d2_absolute_error_score` | $D^2$ regression score function, fraction of absolute error explained. |
| `d2_pinball_score` | $D^2$ regression score function, fraction of pinball loss explained. |
| `d2_tweedie_score` | $D^2$ regression score function, fraction of Tweedie deviance explained. |
| `explained_variance_score` | Explained variance regression score function. |
| `max_error` | The max_error metric calculates the maximum residual error. |
| `mean_absolute_error` | Mean absolute error regression loss. |
| `mean_absolute_percentage_error` | Mean absolute percentage error (MAPE) regression loss. |
| `mean_gamma_deviance` | Mean Gamma deviance regression loss. |
| `mean_pinball_loss` | Pinball loss for quantile regression. |
| `mean_poisson_deviance` | Mean Poisson deviance regression loss. |
| `mean_squared_error` | Mean squared error regression loss. |
| `mean_squared_log_error` | Mean squared logarithmic error regression loss. |
| `mean_tweedie_deviance` | Mean Tweedie deviance regression loss. |
| `median_absolute_error` | Median absolute error regression loss. |
| `r2_score` | $R^2$ (coefficient of determination) regression score function. |
| `root_mean_squared_error` | Root mean squared error regression loss. |
| `root_mean_squared_log_error` | Root mean squared logarithmic error regression loss. |

… и это только для задачи регрессии

Метрики реализованы в библиотеке scikit-learn

# Переобучение

Переобучение (overfitting) — явление, при котором качество модели на новых данных сильно хуже, чем на обучающей выборке



# Переобучение

Причины переобучения

# Переобучение

## Причины переобучения

- Переобучение есть всегда, когда есть оптимизация параметров по конечной (заведомо неполной) выборке

# Переобучение

## Причины переобучения

- Переобучение есть всегда, когда есть оптимизация параметров по конечной (заведомо неполной) выборке
- При небольшом количестве объектов в датасете выше вероятность того, что модель запомнит обучающие данные, а не будет обобщать их на новые, ранее невиданные экземпляры

# Переобучение

## Причины переобучения

- Переобучение есть всегда, когда есть оптимизация параметров по конечной (заведомо неполной) выборке
- При небольшом количестве объектов в датасете выше вероятность того, что модель запомнит обучающие данные, а не будет обобщать их на новые, ранее невиданные экземпляры
- Избыточная сложность модели (большое количество весов). В этом случае лишние степени свободы в модели «тратятся» на чрезмерно точную подгонку под обучающую выборку

# Переобучение

## Причины переобучения

- Переобучение есть всегда, когда есть оптимизация параметров по конечной (заведомо неполной) выборке
- При небольшом количестве объектов в датасете выше вероятность того, что модель запомнит обучающие данные, а не будет обобщать их на новые, ранее невиданные экземпляры
- Избыточная сложность модели (большое количество весов). В этом случае лишние степени свободы в модели «тратятся» на чрезмерно точную подгонку под обучающую выборку

С переобучением можно и нужно бороться! Как это сделать — рассмотрим на следующих занятиях.