

Математика для ML

Паточенко Евгений

НИУ ВШЭ

План занятия

- Функции
- Пределы
- Производные
- Интегралы
- Векторы
- Матрицы

Функции

Функция — это правило, которое связывает входное значение и возвращает результат некоторых математических действий над ним в виде выходного значения

$f(x)$ — обозначение функции, где x — это входная переменная, а f — это выходное значение

$$f(x) = x^2 + 4$$

Множество входных значений называют *областью определения*, а множество выходных значений — *областью значений*

Функции

Функция — это правило, которое связывает входное значение и возвращает результат некоторых математических действий над ним в виде выходного значения

$f(x)$ — обозначение функции, где x — это входная переменная, а f — это выходное значение

$$f(x) = x^2 + 4$$

Множество входных значений называют *областью определения*, а множество выходных значений — *областью значений*

В машинном обучении мы всегда работаем с функциями: выбираем, анализируем, оптимизируем



Функции

Тип функции	Формула	Пояснения	Для чего нужна	Пример
Линейная функция	$f(x) = mx + b$	m — коэффициент наклона, b — сдвиг	Моделирование прямой пропорциональности	Зависимость цены товара от количества. Если $m > 0$, цена растёт, если $m < 0$, падает
Квадратичная функция	$f(x) = ax^2 + bx + c$	a, b, c — константы, $a \neq 0$	Моделирование параболических зависимостей	Затраты на производство товара в зависимости от объёма выпуска
Экспоненциальная функция	$f(x) = ae^{kx}$	a — масштаб, k — скорость роста или распада, e — основание натурального логарифма, $k \neq 0$	Описание процессов роста или распада	Рост популяции бактерий или распад радиоактивных веществ

Функции


Логарифмическая функция	$f(x) = a \ln(bx)$	a, b — константы, $b > 0$	Анализ процессов с затухающей динамикой	Уровень насыщения в маркетинговых кампаниях: добавление рекламы увеличивает продажи, но с каждым разом эффект от рекламы становится меньше
Гиперболическая функция	$f(x) = \frac{a}{x}$	a — масштаб, $x \neq 0$	Моделирование процессов, где результат убывает обратно пропорционально входным данным	Распределение давления в жидкости по мере удаления от источника

Функции




Функции


Пример логарифмической функции: $y = \ln(x)$



Пример гиперболической функции: $y = 1/x$




Пример тригонометрической функции: $y = \sin(x)$




Функции

Пример выпуклой функции: $y = x^2 + 0.5$




Функция везде выпуклая

Пример вогнутой функции: $y = -x^2 + 2$




Функция везде вогнутая

Функция с точкой перегиба: $y = x^3$



Точка, в которой выпуклость
меняется на вогнутость


Функции



Функция везде выпуклая



Функция везде вогнутая



Точка, в которой выпуклость
меняется на вогнутость

Почему это важно?

В машинном обучении мы оптимизируем функцию потерь, то есть ищем такую точку, в которой ее значение минимально (в большинстве случаев) или максимально (реже). Если функция **выпуклая**, мы гарантированно ее оптимизируем. Классический пример — линейная регрессия из прошлого занятия.

Пределы

Предел — это значение, к которому стремится функция $f(x)$, в том числе тогда, когда значение x по правилам математики подставить в функцию нельзя

Обозначение (пример)

$$\lim_{x \rightarrow \infty} \left(1 + \frac{1}{x} \right)^x$$

$\lim$ — предел

$\left(1 + \frac{1}{x} \right)^x$ — функция

$x \rightarrow \infty$ — x на графике будет бесконечно увеличиваться

Пределы

Самый простой способ узнать предел — подставить число, к которому он стремится, в функцию и посчитать выходное значение

Пределы

Самый простой способ узнать предел — подставить число, к которому он стремится, в функцию и посчитать выходное значение

Найдем $\lim_{x \rightarrow 2} (x + 3)$

Пределы

Самый простой способ узнать предел — подставить число, к которому он стремится, в функцию и посчитать выходное значение

Найдем $\lim_{x \rightarrow 2} (x + 3)$

Подставим 2 в $(x + 3)$

Пределы

Самый простой способ узнать предел — подставить число, к которому он стремится, в функцию и посчитать выходное значение

Найдем $\lim_{x \rightarrow 2} (x + 3)$

Подставим 2 в $(x + 3)$

$$\lim_{x \rightarrow 2} (x + 3) = 5$$

Пределы

Подставить число в функцию не всегда возможно — но предел можем посчитать

Пределы

Подставить число в функцию не всегда возможно — но предел можем посчитать

Найдем $\lim_{x \rightarrow 0} \frac{\sin x}{x}$

Пределы

Подставить число в функцию не всегда возможно — но предел можем посчитать

Найдем $\lim_{x \rightarrow 0} \frac{\sin x}{x}$

0 подставить в знаменатель не можем. Но если «подбираться» ближе и ближе — результат стабилизируется около 1

Пределы

Подставить число в функцию не всегда возможно — но предел можем посчитать

Найдем $\lim_{x \rightarrow 0} \frac{\sin x}{x}$

0 подставить в знаменатель не можем. Но если «подбираться» ближе и ближе — результат стабилизируется около 1

$$\lim_{x \rightarrow 0} \frac{\sin x}{x} = 1$$

Пределы


Переменные могут стремиться к бесконечности (или минус бесконечности)

Найдем $\lim_{x \rightarrow \infty} \frac{1}{x}$


Чем больше x , тем сильнее уменьшается значение функции $\frac{1}{x}$, то есть стремится к нулю, хотя нуля никогда не достигнет, так как в $x = 0$ значение функции не определено

$$\lim_{x \rightarrow \infty} \frac{1}{x} = 0$$

Пределы



Предел последовательности: $1/n \rightarrow 0$ (n растёт, значения падают к нулю)



Пределы

Почему это важно?

Многие алгоритмы в машинном обучении строятся на плавных изменениях — например, в градиентном спуске (метод оптимизации функции потерь, о котором будем говорить далее на занятии) шаги становятся все меньше по мере того как мы стремимся к минимуму функции

Чтобы описывать такие процессы, нужно описывать куда стремится функция, если шаг сделать бесконечно маленьким

Производные

Производная — это скорость изменения функции в точке

$$f'(x_0) = \lim_{x \rightarrow 0} \frac{f(x_0 + \Delta x) - f(x_0)}{\Delta x}$$

Насколько выросла функция

Насколько сдвинули по оси x

Строгое определение:

Производная — предел отношения приращения функции в данной точке к приращению аргумента, когда последнее стремится к нулю.

Производные

Производная — это скорость изменения функции в точке

$$f'(x_0) = \lim_{x \rightarrow 0} \frac{f(x_0 + \Delta x) - f(x_0)}{\Delta x}$$

Насколько выросла функция

Насколько сдвинули по оси x


Строгое определение:

Производная — предел отношения приращения функции в данной точке к приращению аргумента, когда последнее стремится к нулю.


Иначе можно написать так: $y'(x_0) = \lim_{x \rightarrow 0} \frac{\Delta y}{\Delta x}$

Производные

Интуиция: производная как наклон горки



Производные



Производные


Почему это важно?

Снова градиентный спуск!

Алгоритмы (в т. ч. градиентный спуск) ищут минимум функции ошибки

Производная показывает **направление**, куда двигаться, чтобы эту ошибку уменьшить

Производные



Производные

Процесс нахождения производной называется дифференцированием. Функция, которая имеет производную в данной точке, называется дифференцируемой

Если функция дифференцируема, это значит, что:

- мы можем посчитать наклон (градиент) в любой точке
- можем корректно двигаться к минимуму
- алгоритм будет сходиться предсказуемо

Производные

Основные правила дифференцирования

1. Константа

$$(c)' = 0$$

2. Степенная функция

$$(x^n)' = n \cdot x^{n-1}, \quad (n \in \mathbb{R})$$

3. Константа на функцию

$$(c \cdot f(x))' = c \cdot f'(x)$$

4. Сумма / разность

$$(f(x) \pm g(x))' = f'(x) \pm g'(x)$$

5. Произведение

$$(f(x) \cdot g(x))' = f'(x)g(x) + f(x)g'(x)$$

6. Частное

$$\left(\frac{f(x)}{g(x)} \right)' = \frac{f'(x)g(x) - f(x)g'(x)}{(g(x))^2}$$

7. Сложная функция (правило цепочки)

$$(f(g(x)))' = f'(g(x)) \cdot g'(x)$$

Интеграл

Математически интегрирование — это операция, обратная дифференцированию

$$\int f(x)dx$$

$\int$ — знак интеграла


$f(x)$ — функция, которую интегрируем

dx — указывает на то, что переменная интегрирования — x

Интеграл

Определенный интеграл — это площадь под графиком между точками a и b на оси x

$$\int_a^b f(x) dx$$




- Делим заштрихованную область на узкие прямоугольники
- Складываем площади прямоугольников
- Делаем ширину прямоугольников все меньше

В пределе (тут снова нужен предел!) мы получаем точную площадь. Это и есть интеграл.

Интеграл

Интеграл в вероятностях: под «колоколом» нормального распределения заштрихованная область показывает вероятность попасть в диапазон $[-1, 1]$



Интеграл

Почему это важно?

- Интеграл позволяет найти среднее значение функции на отрезке
- В теории вероятностей интегралы описывают площадь под кривой распределения
- Интеграл может пригодиться для нормализации: при работе с непрерывными распределениями интеграл нужен, чтобы сумма вероятностей была равна 1:

$$\int_{-\infty}^{+\infty} f(x)dx = 1$$

Интеграл

Если **производная** отвечает на вопрос «как быстро меняется функция в точке», то **интеграл** отвечает на вопрос «какова накопленная сумма изменения/площадь под функцией»

Векторы

Вектор — это упорядоченный набор чисел.

$$\vec{x} = (x_1, x_2, x_3)$$

Может быть вектор-строкой: $\vec{x} = (x_1, x_2, x_3)$ или вектор-столбцом: $\vec{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$

Векторы

Некоторые операции над векторами

Сложение

$$(1, 2) + (3, 4) = (4, 6)$$

Скалярное произведение

$$(1, 2) * (3, 4) = (1 * 3 + 2 * 4) = 11$$

(мера «сходства» векторов)

Умножение на число (на скаляр)

$$2 \times (1, 2) = (2, 4)$$

Длина (норма):

$$\|\vec{x}\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

Векторы

Почему это важно?

В машинном обучении в виде векторов представлены данные (признаки), веса модели, градиенты. Мы все время имеем дело с векторными представлениями каких-либо данных или преобразуем данные в вектора для удобства или вообще обеспечения возможности работы с ними (например, модель не может обработать слова — для работы с естественным языком каждое слово нужно преобразовать в вектор с цифрами)

Матрицы

Матрица — это по сути набор векторов:

1	2	3
4	5	6
7	8	9

Единичная матрица:

1	0	0
0	1	0
0	0	1

Матрицы

Некоторые операции над матрицами

- Транспонирование (меняем местами строки и столбцы)

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \longrightarrow \mathbf{A}^T = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}$$

- Умножение матрицы на вектор (линейное преобразование: например, поворот, растяжение)

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \times \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 7 \\ 15 \end{bmatrix}$$

Матрицы

Некоторые операции над матрицами

- Умножение матрицы на матрицу (последовательные преобразования)

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \times \begin{bmatrix} 2 & 0 \\ 1 & 2 \end{bmatrix} = \begin{bmatrix} (1 \cdot 2 + 2 \cdot 1) & (1 \cdot 0 + 2 \cdot 2) \\ (3 \cdot 2 + 4 \cdot 1) & (3 \cdot 0 + 4 \cdot 2) \end{bmatrix} = \begin{bmatrix} 4 & 4 \\ 10 & 8 \end{bmatrix}$$

Матрицы

Обратная матрица

Матрица A^{-1} называется обратной к матрице A , если $A \cdot A^{-1} = I$ (единичной матрице)

В линейной регрессии аналитическое решение считает веса через обратную матрицу

$$w = (X^T X)^{-1} X^T y$$

Почему это важно? Если матрица признаков плохо обратима, веса становятся нестабильными и модель плохо обобщает —> понимание этого позволяет выявить мультиколлинеарность (когда признаки линейно связаны между собой) и применять регуляризацию (будем проходить на следующем занятии)

Матрицы

Почему это важно?

- В машинном обучении мы имеем дело с матрицами признаков, где объекты — это вектор-строки, а признаки — это вектор-столбцы

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{bmatrix}$$

Матрицы

Почему это важно?

- **Линейные модели — по сути и есть матричные операции**

Линейная регрессия, логистическая регрессия сводятся к

$$y = X \cdot \beta$$

где

X — матрица данных, β — вектор весов модели, y — предсказания модели

Это позволяет делать предсказания сразу для всех объектов одновременно с помощью одного умножения матриц

Матрицы

Почему это важно?

- **Нейросети — матричные преобразования**

Каждый слой нейросети — это преобразование:

$$h = f(W \cdot x + b)$$

где

W — матрица весов слоя, x — входной вектор, b — вектор смещений, f — функция, которая добавляет нелинейности