Градиентный спуск

Паточенко Евгений

НИУ ВШЭ

План занятия

- Задача оптимизации
- Градиентный спуск
- Модификации градиентного спуска

Задача оптимизации

Напоминание

На первом занятии мы уже упоминали термин «оптимизировать»:

Задача оптимизации

Напоминание

На первом занятии мы уже упоминали термин «оптимизировать»:

Обучение — это по сути процесс подбора весов или параметров модели так, чтобы *оптимизировать* (в большинстве случаев — минимизировать) функцию потерь

Задача оптимизации

Определение

Оптимизация — это задача нахождения экстремума (минимума или максимума) целевой функции в некоторой области конечномерного векторного пространства, ограниченной набором линейных и/или нелинейных равенств и/или неравенств

Задача оптимизации

Постановка задачи

Среди элементов x, образующих множества X , найти такой элемент x^*, который доставляет минимальное (максимальное) значение $f(x^*)$ заданной функции $f(x)$.

Задача оптимизации

Постановка задачи

Среди элементов x, образующих множества X , найти такой элемент x^*, который доставляет минимальное (максимальное) значение $f(x^*)$ заданной функции $f(x)$.

В простейшем случае линейной регрессии:

Элементы x, образующие множества X — веса модели

Функция $f(x)$ — среднеквадратичная ошибка

Задача оптимизации

Постановка задачи

Среди элементов x, образующих множества X , найти такой элемент x^*, который доставляет минимальное (максимальное) значение $f(x^*)$ заданной функции $f(x)$

В простейшем случае линейной регрессии:

Элементы x, образующие множества X — веса модели

Функция $f(x)$ — среднеквадратичная ошибка

Почему оптимизация среднеквадратичной ошибки — простейший случай?

Задача оптимизации

Оптимизация MSE

Функция среднеквадратичной ошибки — *выпуклая*

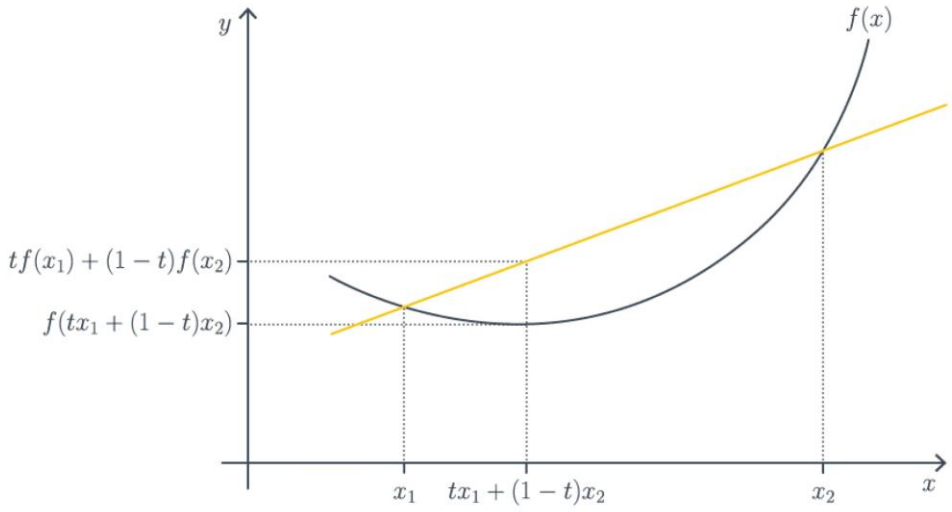

Задача оптимизации

Оптимизация MSE

Функция среднеквадратичной ошибки — *выпуклая*

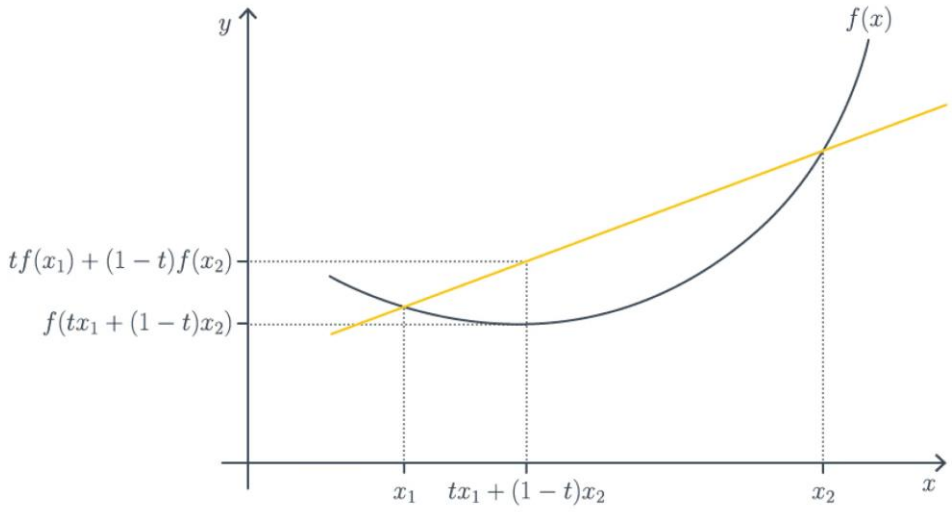

Для нас это означает, что у такой функции *локальный и глобальный минимумы совпадают* (в отличие от случая на картинке ниже)

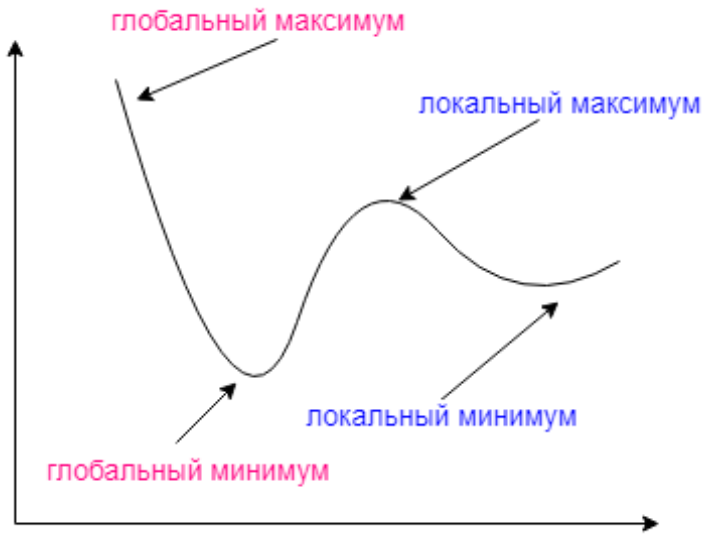

Задача оптимизации

Поиск минимума

Градиент – это вектор, в направлении которого функция быстрее всего растет

Антиградиент (вектор, противоположный градиенту) — вектор, в направлении которого функция быстрее всего убывает, при этом в общем случае он *не указывает точно на точку минимума функции*

Вектор градиента обозначают

$grad$ или ∇

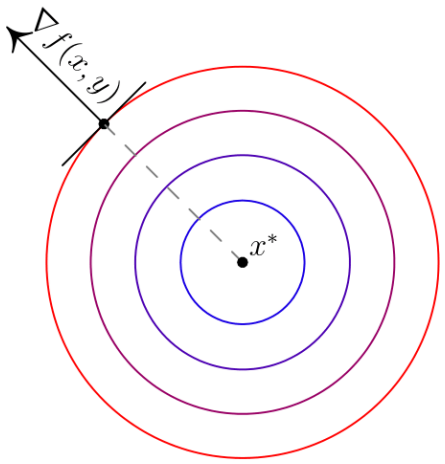

$f(x,y) = x^2 + y^2$

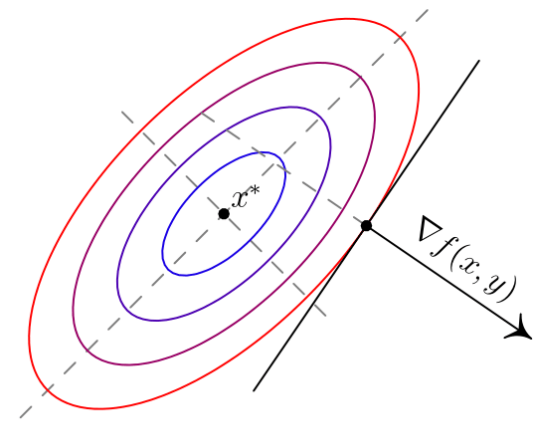

$f(x,y) = \frac{3}{2}(x-y)^2 + \frac{1}{3}(x+y)^2$

Задача оптимизации

Градиент

Если f — функция n переменных x_1,…, x_n, ее градиентом называется n-мерный вектор $\left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n}\right)$, компоненты которого равны частным производным f по всем ее аргументам

Для одномерного пространства градиентом функции $f(x)$ будет $\frac{\partial f}{\partial x}$

Градиентный спуск

Определение

Градиентный спуск — метод оптимизации первого порядка для нахождения локального экстремума (минимума или максимума) функции с помощью движения вдоль градиента

Методы оптимизации:

- прямые — требуют только вычислений целевой функции в точках приближений
- первого порядка — требуют вычисления первых частных производных функции
- второго порядка — требуют вычисления вторых частных производных, то есть гессиана целевой функции

Градиентный спуск

Алгоритм

- Выбираем x_0 — начальную точку градиентного спуска.
- Каждую следующую точку выбираем по формуле:

$$x_{k+1} = x_k - \alpha \nabla f(x_k),$$

где α — это размер шага (learning rate)

- Проверяем критерий останова. Если не выполнен, повторяем предыдущий шаг. Выполнен — останавливаемся

Градиентный спуск

Алгоритм

При обучении модели мы подбираем веса. Соответственно, формула

$$x_{k+1} = x_k - \alpha \nabla f(x_k),$$

Может быть записана так:

$$\beta_{k+1} = \beta_k - \alpha \nabla f(\beta_k)$$

То есть на каждом шаге для нахождения новой точки мы *обновляем веса*

Градиентный спуск

Инициализация весов

Градиентный спуск

Инициализация весов

- $\beta_k = 0, k = 1, \dots, n$

Градиентный спуск

Инициализация весов

- $\beta_k = 0, k = 1, \dots, n$
- Небольшие случайные значения: $\beta_k \coloneqq \mathrm{random}(-\varepsilon, \varepsilon)$ из некоторого распределения

Градиентный спуск

Инициализация весов

- $\beta_k = 0, k = 1, \dots, n$
- Небольшие случайные значения: $\beta_k \coloneqq \mathrm{random}(-\varepsilon, \varepsilon)$ из некоторого распределения
- Обучение по небольшой случайной подвыборке объектов

Градиентный спуск

Инициализация весов

- $\beta_k = 0, k = 1, \dots, n$
- Небольшие случайные значения: $\beta_k \coloneqq \mathrm{random}(-\varepsilon, \varepsilon)$ из некоторого распределения
- Обучение по небольшой случайной подвыборке объектов
- Мультистарт — многократный запуск из разных случайных начальных приближений и выбор лучшего решения

Градиентный спуск

Выбор градиентного шага (скорость обучения, learning rate)

α — это гиперпараметр, который мы подбираем и который влияет на качество и скорость обучения. При неудачном выборе метод может либо слишком медленно сходиться, либо пропускать минимум

Градиентный спуск

Выбор градиентного шага (скорость обучения, learning rate)

α — это гиперпараметр, который мы подбираем и который влияет на качество и скорость обучения. При неудачном выборе метод может либо слишком медленно сходиться, либо пропускать минимум

- Если хотим, чтобы получаемая точка минимума была как можно ближе к точному значению, выбираем как можно меньшую α
- Если важнее скорость и хотим уменьшить количество шагов, выбираем как можно большую α

Градиентный спуск

Выбор градиентного шага (скорость обучения, learning rate)

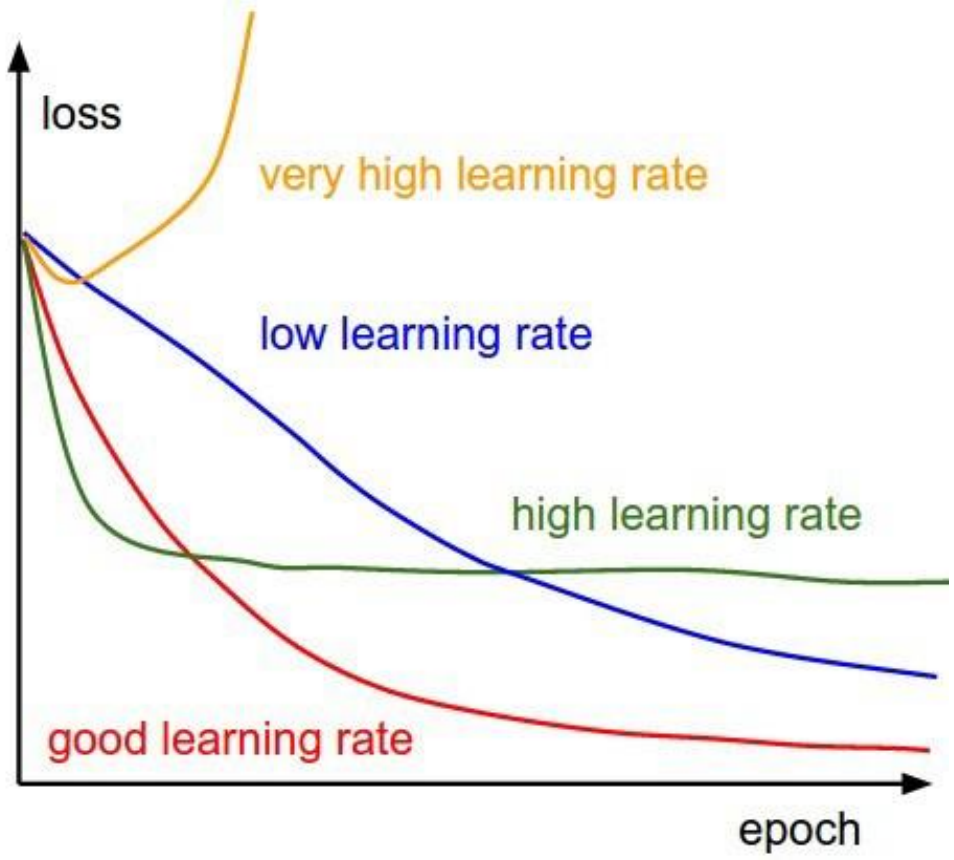

Градиентный спуск

Критерии останова

Градиентный спуск

Критерии останова

- Остановка через заранее заданное число шагов

Градиентный спуск

Критерии останова

- Остановка через заранее заданное число шагов
- Остановка на основе изменения функционала $\left|Q\left(\beta^{k+1}\right) - Q(\beta^{k})\right| < \varepsilon$

Градиентный спуск

Критерии останова

- Остановка через заранее заданное число шагов
- Остановка на основе изменения функционала $\left|Q\left(\beta^{k+1}\right) - Q(\beta^{k})\right| < \varepsilon$
- Остановка через изменение весов $\left\|\beta^{k+1} - \beta^{k}\right\| < \varepsilon$

Градиентный спуск

Недостаток градиентного спуска

Градиентный спуск

Недостатки градиентного спуска

- На каждом шаге мы вычисляем целую матрицу производных — по каждому весу от каждого объекта. Это затратно и по времени, и по памяти.

Градиентный спуск

Недостатки градиентного спуска

- На каждом шаге мы вычисляем целую матрицу производных — по каждому весу от каждого объекта. Это затратно и по времени, и по памяти.
- Может застрять в локальном минимуме

Модификации градиентного спуска

Стохастический градиентный спуск (SGD)

На каждом шаге выбираем один случайный (отсюда — «стохастический» в названии метода) объект и двигаемся в сторону антиградиента по нему

Такая модификация решает техническую проблему ресурсоемкости градиентного спуска, при этом вычисленный градиент, хоть и придет при правильно подобранном шаге обучения и начальной точке в точку минимума, может потребовать больше шагов, чтобы сойтись

Модификации градиентного спуска

Mini-batch SGD

На каждом шаге выбираем подвыборку объектов (*batch size, например, 32, 64 и т. д.*) и двигаемся в сторону антиградиента функции потерь, вычисленной по батчу

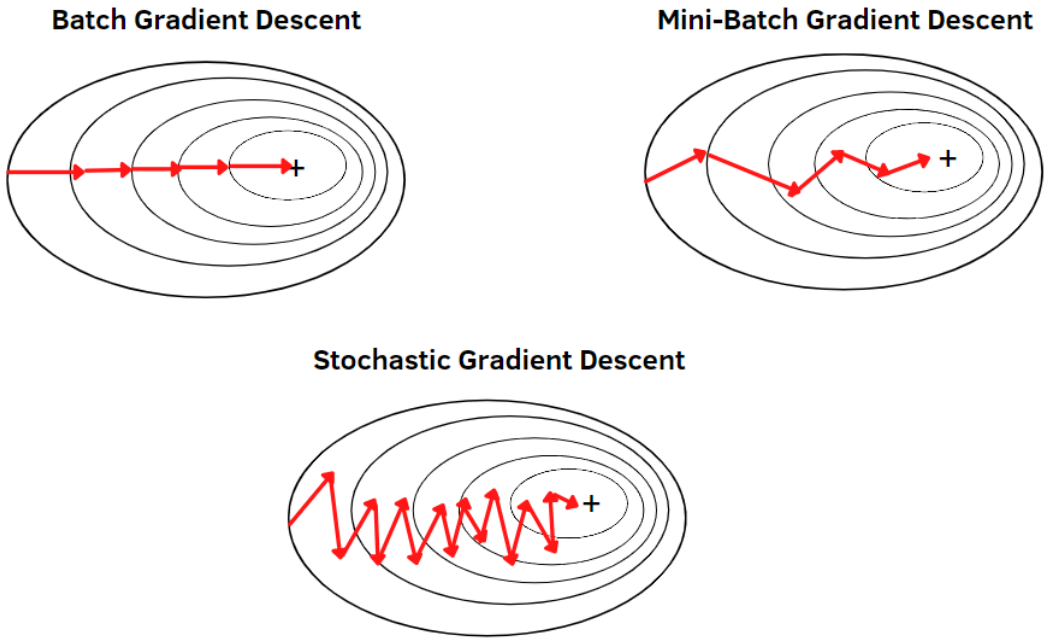

Модификации градиентного спуска

Momentum

Добавляем к градиентному шагу еще одно слагаемое так, чтобы использовать информацию о предыдущих градиентах:

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \eta_k (x_k - x_{k-1})$$

Такой подход, когда каждое следующее значение рекуррентно учитывает несколько предыдущих называют экспоненциальным сглаживанием.

Можно также представить в виде двух параллельных процессов:

1. $v_{k+1} = \eta_k v_k - \alpha \nabla f(x_k)$
2. $x_{k+1} = x_k + v_{k+1}$

Модификации градиентного спуска

Momentum

Преимущества:

- Удается сгладить направление каждого из шагов, что решает проблему частой смены направления шага (в том числе из-за небольшого батча) и как следствие решается проблема общей низкой скорости сходимости
- За счет инерции шага удается перешагивать некоторые локальные минимумы

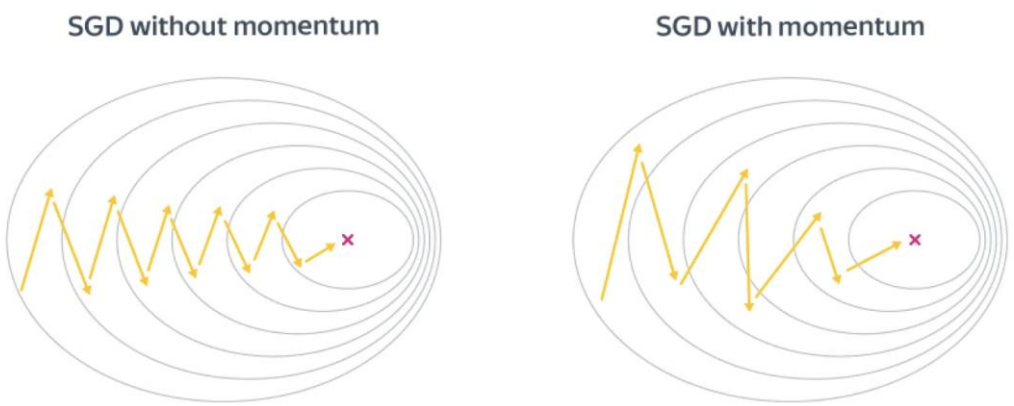

Модификации градиентного спуска

Accelerated Gradient Descent (Nesterov Momentum)

Модифицируем предыдущий метод и рассчитываем градиент не в текущей точке, а как будто бы в точке, в которую мы бы пошли, следуя импульсу

1. $v_{k+1} = \eta_k v_k - \alpha \nabla f(x_k + \eta_k v_k)$
2. $x_{k+1} = x_k + v_{k+1}$

Позволяет значительно повысить устойчивость и скорость сходимости в некоторых случаях (в частности, для выпуклых функций)

Модификации градиентного спуска

Adagrad (Adaptive Gradient)

Адаптация стохастического градиентного спуска, позволяющая динамически менять learning rate

Зафиксируем α и запишем формулу обновления:

$$G_{k+1} = G_k + \left(\nabla f(x_k)\right)^2$$

$$x_{k+1} = x_k - \frac{\alpha}{\sqrt{G_{k+1} + \varepsilon}} \nabla f(x_k)$$

Модификации градиентного спуска

Adagrad (Adaptive Gradient)

Возведение в квадрат и деления векторов покомпонентные, то есть мы подбираем размер шага для каждой координаты по отдельности. ε на практике оставляется дефолтными $1e-8$.

Если мы вышли на плато по какой-то координате и соответствующая компонента градиента начала затухать, нельзя уменьшать размер шага слишком сильно, чтобы не остаться на плато, при этом в целом уменьшать его нужно, так как плато может содержать оптимум

Если градиент долго слишком большой, может быть нужно увеличить размер шага

Модификации градиентного спуска

RMSProp (Root Mean Square Propagation)

Модификация Adagrad, в которой мы не складываем нормы градиентов, а усредняем их в скользящем режиме:

$$G_{k+1} = \gamma G_k + (1-\gamma)\left(\nabla f(x_k)\right)^2$$

$$x_{k+1} = x_k - \frac{\alpha}{\sqrt{G_{k+1} + \varepsilon}} \nabla f(x_k)$$

В этом методе также учитывается история градиентов, но размер шага уменьшается не так быстро

Модификации градиентного спуска

Adam (ADAptive Momentum)

Алгоритм, который считается решением по умолчанию и включает в себя:

— Экспоненциальное сглаживание для градиента (Momentum)

— Вычисление градиента в точке, определяемой инерцией (Nesterov Momentum)

— Нормировку градиента для адаптивного регулирования шага по разным его компонентам (Adagrad + RMSProp)

При использовании Adam очень важно правильно подобрать гиперпараметр α. Чаще всего начинают со значения $3e-4$

Еще немного про шаг обучения

Расписания

Часто шаг обучения понижают итеративно. Его можно понижать:

— Каждые n итераций ([ссылка на документацию LRScheduler в Pytorch](#))

— При выходе функции потерь на плато

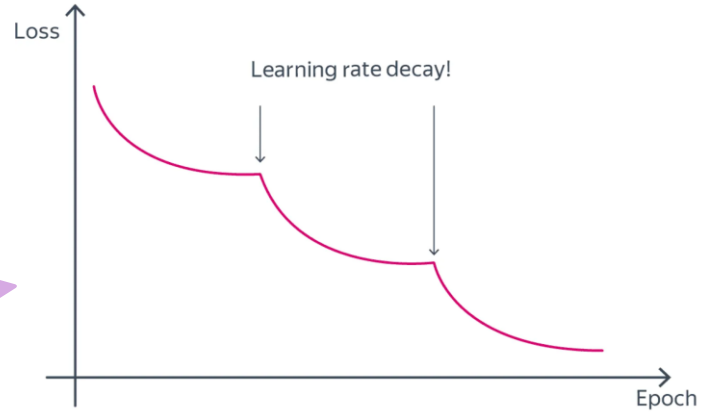

— Сделав сначала warmup (первые *warmup_steps* шагов происходит линейный рост lr, затем он начинает уменьшаться как $\frac{1}{\sqrt{t}}$, где t — число итераций