

Базовые методы обучения моделей

Паточенко Евгений

НИУ ВШЭ

План занятия

- Регуляризация в линейной регрессии
- Кросс-валидация
- Кодирование категориальных признаков

Напоминание

Линейная регрессия

Базовая модель машинного обучения и статистики, используемая для оценки зависимости между одной зависимой переменной (целевой) и одной или несколькими независимыми переменными (признаками), при этом целевая переменная — непрерывная величина


Общий вид уравнения линейной регрессии

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n + \varepsilon, \text{ где}$$

- y — зависимая (целевая) переменная
- $x_1, x_2, \dots, x_n$ — независимые переменные (признаки)
- β_0 — свободный член (intercept)
- $\beta_1, \beta_2, \dots, \beta_n$ — коэффициенты (веса) модели
- ε — ошибка модели (ошибка прогноза)

Напоминание

Переобучение (overfitting) — явление, при котором качество модели на новых данных сильно хуже, чем на обучающей выборке



Напоминание

Описание датасета

Прежде всего необходимо понять как можно больше про данные, с которыми будем работать:

- Посмотреть объем и полноту
- Проверить характеристики данных
- Определить распределение
- Узнать есть ли зависимость между признаками и признаков с целевой переменной

Напоминание

Описание датасета

Прежде всего необходимо понять как можно больше про данные, с которыми будем работать:

- Посмотреть объем и полноту
- Проверить характеристики данных
- Определить распределение
- Узнать есть ли зависимость между признаками и признаков с целевой переменной

Регуляризация

Зачем нужна?

- При сильной корреляции признаков веса при них теряют физический смысл, а задача оптимизации $Q(\beta) \rightarrow \min$ может иметь бесконечное число решений
- Возможна парадоксальная ситуация: признак, который должен повышать целевую переменную, получает отрицательный вес
- Это делает модель неточной и неинтерпретируемой
- Неадекватность знаков или величины весов — верный признак **мультиколлинеарности** (сильной линейной зависимости между признаками)

Регуляризация

Зачем нужна?

При регуляризации мы модифицируем функцию потерь, добавляя штраф за слишком большие веса

Регуляризация

Зачем нужна?

При регуляризации мы модифицируем функцию потерь, добавляя штраф за слишком большие веса

В общем виде это можно записать так:

$$Q_{\lambda}(\beta) = Q(\beta) + \lambda R(\beta),$$

где λ — коэффициент регуляризации (гиперпараметр, который отражает степень силы штрафа), а $R(\beta)$ — регуляризатор

Регуляризация

Зачем нужна?

При регуляризации мы модифицируем функцию потерь, добавляя штраф за слишком большие веса

В общем виде это можно записать так:

$$Q_{\lambda}(\beta) = Q(\beta) + \lambda R(\beta),$$

где λ — коэффициент регуляризации (гиперпараметр, который отражает степень силы штрафа), а $R(\beta)$ — регуляризатор

λ подбирают на валидационной выборке по логарифмической шкале (например, от $1e-2$ до $1e+2$)

Регуляризация

L2-регуляризация (Ridge)

$$R(\beta) = \|\beta\|_2^2 = \sum_{i=1}^n \beta_i^2$$
$$Loss = MSE + \lambda \sum \beta_i^2$$

L1-регуляризация (Lasso)

$$R(\beta) = \|\beta\|_1 = \sum_{i=1}^n |\beta_i|$$
$$Loss = MSE + \lambda \sum |\beta_i|$$

Регуляризация

L2-регуляризация (Ridge)

Использует сумму квадратов весов, то есть L2-норму

Штрафует большие значения весов, заставляя их приближаться к нулю, но не зануляет их полностью. Уменьшает влияние шума в данных на модель

В библиотеке scikit-learn реализована в виде класса Ridge ([ссылка на документацию](#))

Регуляризация

L1-регуляризация (Lasso)

Использует сумму модулей весов, то есть L1-норму

Штрафует все веса одинаково, тем самым зануляя наименее важные. Успешно используется для отбора признаков

В библиотеке scikit-learn реализована в виде класса Lasso ([ссылка на документацию](#))

Регуляризация

ElasticNet

Комбинированный подход к регуляризации, сочетающий механизмы Lasso и Ridge

$$R(\beta) = \|\beta\|_1 + \|\beta\|_2^2 = \sum_{i=1}^n |\beta_i| + \sum_{i=1}^n \beta_i^2$$


$$Loss = MSE + \lambda_1 \sum |\beta_i| + \lambda_2 \sum \beta_i^2$$

Совмещает плюсы L1 и L2: отбирает признаки и сглаживает веса

В библиотеке scikit-learn реализована в виде класса ElasticNet ([ссылка на документацию](#))

Регуляризация

Сравнение методов регуляризации




Регуляризация

Плюсы и минусы регуляризации

- + Повышает устойчивость весов в случае мультиколлинеарности
- + Повышает обобщающую способность алгоритма
- + Снижает риск переобучения
- Высокие вычислительные затраты на кросс-валидацию для подбора силы регуляризации λ

Напоминание

Разбиение данных на обучающую и тестовую выборку



Кросс-валидация

Определение

Кросс-валидация — это процедура для оценки качества работы модели

Наиболее часто используемый механизм — **k-Fold CV**: фиксируется тестовая выборка, а обучающая — разделяется на k равных частей (фолдов)


На каждом шаге одна часть используется как тестовая, остальные $k-1$ — для обучения

Процесс повторяется k раз с последовательной сменой валидационной части

Итоговое качество модели — среднее значение метрики по всем фолдам, либо по отложенной выборке

Кросс-валидация


k-Fold CV



Рекомендуем ознакомиться с материалом о кросс-валидации и ее реализации в [scikit-learn](https://scikit-learn.org/)

Кросс-валидация

Выбор количества блоков в k-Fold CV




Проблемы при маленьком k?

Проблемы при большом k?

Кросс-валидация

Выбор количества блоков в k-Fold CV



При маленьком k оценка может быть пессимистично занижена из-за маленького размера тренировочной части

При большом k оценка может иметь большую дисперсию из-за маленького размера валидационной части и долго обучать много моделей

Кросс-валидация

Stratified k-Fold

Для разбиения на фолды используется стратификация, то есть каждый фолд содержит примерно такое же соотношение классов, как и все исходное множество.

Полезен для использования с датасетами с дисбалансом классов, когда при обычном случайном разбиении (random split) некоторые фолды могут содержать слишком мало экземпляров некоторых классов или не содержать их вовсе.

[Реализация в scikit-learn](#)

Кросс-валидация

Перебор гиперпараметров

- **Grid Search** — перебор по сетке
 - Для каждого гиперпараметра фиксируется несколько значений
 - Последовательно перебираются все возможные комбинации значений гиперпараметров, на каждой из комбинаций обучается и тестируется модель
 - Выбирается модель с наилучшим качеством

Минус метода: если комбинаций значений слишком много, подбор будет длиться неразумно долго

[Реализация в scikit-learn](#)

Кросс-валидация

Перебор гиперпараметров

- **Random Search**

- Для каждого гиперпараметра задается распределение, из которого семплированием выбираются значения
- Последовательно перебираются отобранные случайные комбинации значений, на каждой из комбинаций обучается и тестируется модель
- Выбирается модель с наилучшим качеством

Преимущество: при достаточно большом количестве перебираемых значений RS может за то же число итераций, что GS, рассмотреть более разнообразные значения. Таким образом, мы оптимизируем поиск без риска пропустить хорошую комбинацию


[Реализация в scikit-learn](#)

Кросс-валидация

Перебор гиперпараметров

- **Последовательный халвинг (Successive halving, SH)** — все комбинации параметров оцениваются с небольшим количеством ресурсов на первой итерации. На вторую итерацию с увеличенными ресурсами проходят только те комбинации, которые показали лучшие результаты. Процесс повторяется до нахождения наилучшей комбинации

Реализация в [scikit-learn по полной сетке](#) и [с семплированием](#)



Кросс-валидация

Другие методы

- Байесовская оптимизация
- Tree-structured Parzen Estimator (TPE)
- Population Based Training (PBT)
- Hyperband
- и т. д.

В большинстве случаев используются Grid Search и Random Search

Кросс-валидация

Основные библиотеки для подбора гиперпараметров

- [Scikit-learn](#)
- [Hyperopt](#)
- [Optuna](#)

Напоминание

Типы признаков

- Бинарные
- Категориальные
- Непрерывные
- Географические данные
- Дата и время
- и многие другие

Напоминание

Типы признаков

- Бинарные
- **Категориальные**
- Непрерывные
- Географические данные
- Дата и время
- и многие другие

Кодирование категориальных признаков

Label Encoding

Заменяет каждую категорию на уникальное целое число

Label Encoding

исходные данные

Район	Тип дома	Цена, млн
Центр	Кирпич	12.5
Север	Панель	7.2
Юг	Монолит	9.8
Север	Кирпич	8.1
Центр	Панель	10.3

→

после кодирования

Район	Тип дома	Цена, млн
0	0	12.5
1	1	7.2
2	2	9.8
1	0	8.1
0	1	10.3

Район: Центр=0, Север=1, Юг=2

Тип дома: Кирпич=0, Панель=1, Монолит=2

Кодирование категориальных признаков

One-Hot Encoding (OHE)

Создает новую бинарную колонку для каждой категории

One-Hot Encoding

исходные данные

Район	Тип дома	Цена, млн
Центр	Кирпич	12.5
Север	Панель	7.2
Юг	Монолит	9.8
Север	Кирпич	8.1
Центр	Панель	10.3



после кодирования

Район Центр	Район Север	Район Юг	Тип дома	Цена, млн
1	0	0	Кирпич	12.5
0	1	0	Панель	7.2
0	0	1	Монолит	9.8
0	1	0	Кирпич	8.1
1	0	0	Панель	10.3

Кодирование категориальных признаков

Binary Encoding

Сначала используется Label Encoding, затем лейблы переводятся в двоичный вид

Binary Encoding				
категория	порядковый номер	двоичный код	биты по столбцам	
Район	Номер	Двоичный код	Район бит 1	Район бит 2
Центр	0	00	0	0
Север	1	01	0	1
Юг	2	10	1	0
Север	1	01	0	1
Центр	0	00	0	0

Кодирование категориальных признаков

Target (Mean) Encoding

Заменяет каждую категорию на среднее значение целевой переменной

Target (Mean) Encoding

исходные данные		
Район	Тип дома	Цена, млн
Центр	Кирпич	12.5
Север	Панель	7.2
Юг	Монолит	9.8
Север	Кирпич	8.1
Центр	Панель	10.3

→

после кодирования		
Район	Тип дома	Цена, млн
11.4	Кирпич	12.5
7.65	Панель	7.2
9.8	Монолит	9.8
7.65	Кирпич	8.1
11.4	Панель	10.3

Кодирование категориальных признаков

Target (Mean) Encoding

В чем минус метода?

Кодирование категориальных признаков

Target (Mean) Encoding

В чем минус метода?

Мы заранее закладываем информацию о целевой переменной, тем самым переобучаемся

Кодирование категориальных признаков

Target (Mean) Encoding

В чем минус метода?

Мы заранее закладываем информацию о целевой переменной, тем самым переобучаемся

Leave-One-Out Encoding

Модификация Target Encoding, в которой для каждого объекта исключается его собственное значение при расчете среднего, что позволяет уменьшить утечку информации (data leakage)

Кодирование категориальных признаков

Leave-One-Out Encoding

Leave-One-Out Encoding

исходные данные

Район	Тип дома	Цена, млн
Центр	Кирпич	12.5
Север	Панель	7.2
Юг	Монолит	9.8
Север	Кирпич	8.1
Центр	Панель	10.3



после кодирования

Район	Тип дома	Цена, млн
10.3	Кирпич	12.5
8.1	Панель	7.2
9.58	Монолит	9.8
7.2	Кирпич	8.1
12.5	Панель	10.3

Кодирование категориальных признаков

Ordinal Encoding

Кодируем целыми числами, но порядок задаем осмысленно и намеренно

Ordinal Encoding

исходные данные

Состояние	Район	Цена, млн
Отличное	Центр	12.5
Треб. ремонта	Север	7.2
Хорошее	Юг	9.8
Удовл.	Север	8.1
Хорошее	Центр	10.3



после кодирования

Состояние	Район	Цена, млн
3	Центр	12.5
0	Север	7.2
2	Юг	9.8
1	Север	8.1
2	Центр	10.3

Порядок: Треб. ремонта=0 · Удовл.=1 · Хорошее=2 · Отличное=3