

Деревья решений Критерии информативности

Паточенко Евгений


НИУ ВШЭ

План занятия

- Деревья решений
- Критерии информативности
- Критерии останова
- Стрижка дерева

Деревья решений

- Семейство моделей, которые позволяют восстанавливать нелинейные зависимости произвольной сложности
- Могут использоваться как для классификации, так и для регрессии
- Строит прогноз, следуя иерархии простых условий (предикатов) от корня к листьям
- Легко интерпретируются, поскольку процесс структурно схож с человеческой логикой принятия решений



Источник: <https://mljar.com/glossary/decision-trees/>

Деревья решений

Каждой вершине v приписана функция (предикат) $\beta_v: X \rightarrow \{0,1\}$

Каждой листовой вершине v приписан прогноз $c_v \in Y$ (для классификации – класс или вероятность класса, для регрессии – действительное значение целевой переменной)



Деревья решений

Жадный алгоритм построения

1 шаг

- найдем наилучшее разбиение всей выборки X на две части: $R_1(j, t) = \{x \mid x_j < t\}$ и $R_2(j, t) = \{x \mid x_j \geq t\}$ с точки зрения некоторого функционала $Q(X, j, t)$:
- найдем наилучшие j и t
- создадим корень дерева, поставив в него предикат $[x_j < t]$.

Деревья решений

Жадный алгоритм построения

1 шаг

- найдем наилучшее разбиение всей выборки X на две части: $R_1(j, t) = \{x \mid x_j < t\}$ и $R_2(j, t) = \{x \mid x_j \geq t\}$ с точки зрения некоторого функционала $Q(X, j, t)$:
- найдем наилучшие j и t
- создадим корень дерева, поставив в него предикат $[x_j < t]$.

2 шаг

Для каждой из полученных подвыборок R_1 и R_2 рекурсивно применим шаг 1.

В каждой вершине на каждом шаге проверяем, не выполнилось ли условие останова.

Деревья решений

Жадный алгоритм построения

1 шаг

- найдем наилучшее разбиение всей выборки X на две части: $R_1(j, t) = \{x \mid x_j < t\}$ и $R_2(j, t) = \{x \mid x_j \geq t\}$ с точки зрения некоторого функционала $Q(X, j, t)$:
- найдем наилучшие j и t
- создадим корень дерева, поставив в него предикат $[x_j < t]$.

2 шаг

Для каждой из полученных подвыборок R_1 и R_2 рекурсивно применим шаг 1.


В каждой вершине на каждом шаге проверяем, не выполнилось ли условие останова.

Если выполнилось, то объявляем вершину листом и записываем в него предсказание.

Деревья решений

Пример


Найдем лучший предикат



Деревья решений

Пример


Найдем лучший предикат



Деревья решений

Пример



Найдем лучший предикат



Деревья решений

Пример



Нашли лучшее первое
ветвление



Деревья решений

Пример

Нашли лучшее первое
ветвление





Продолжим
этую ветку

Деревья решений

Пример


Нашли лучшее первое
ветвление



Деревья решений

Пример


Построили все дерево



Деревья решений

Пример

Построили все дерево



Деревья решений

Переобучение



Для любой выборки можно построить решающее дерево, не допускающее на ней ни одной ошибки: в каждом листе разместить по одному объекту выборки

Такое дерево скорее всего будет переобученным и не сможет показать хороший результат на новых данных

Деревья решений

Пример

Остановимся раньше!



1 ошибка, но
скорее всего будет
лучше на тесте!

Деревья решений

Что влияет на построение дерева

- вид предикатов в вершинах
- функционал качества $Q(X, j, t)$
- критерий останова

Критерии информативности

Пусть R – множество объектов, попадающих в вершину на данном шаге, а R_l и R_r - объекты, попадающие в левую и правую ветки после разбиения.

Критерий информативности (impurity criterion) оценивает качество распределения целевой переменной среди объектов множества R (т. е. это мера неоднородности или разнообразие целевых переменных внутри группы R)

Чем меньше разнообразие целевой переменной, тем меньше должно быть значение критерия информативности — соответственно, мы минимизируем его значение:

$$H(R_l) \rightarrow \min, H(R_r) \rightarrow \min$$


Функционал качества Q мы при этом будем максимизировать

$$Q(R, j, t) = H(R) - \frac{|R_l|}{|R|} H(R_l) - \frac{|R_r|}{|R|} H(R_r) \rightarrow \max_{j,t}$$

Критерии информативности

Задача регрессии


Предположим, что в лист дерева попало несколько объектов. В каждом листе дерево предсказывает константу. Какую константу выгоднее всего выдать в качестве ответа?



Критерии информативности

Задача регрессии

Если в качестве функционала ошибки в листе использовать среднеквадратичную ошибку, то в качестве ответа надо выдавать среднее значение целевых переменных всех объектов, попавших в лист.



Критерии информативности

Вид критерия информативности

- В каждом листе дерево выдает константу c (вещественное число – в регрессии, класс или вероятность класса – в классификации).
- Чем лучше объекты в листе предсказываются этой константой, тем меньше средняя ошибка на объектах:

$$H(R) = \min_{c \in \mathbb{R}} \frac{1}{|R|} \sum_{(x_i, y_i) \in R} L(y_i, c),$$

где $L(y, c)$ – некоторая функция потерь.

Критерии информативности

$H(R)$ в задаче регрессии

Если в качестве функции потерь взять квадратичную ошибку, то

$$H(R) = \min_{c \in \mathbb{R}} \frac{1}{|R|} \sum_{(x_i, y_i) \in R} (y_i - c)^2.$$

Критерии информативности

H(R) в задаче регрессии

Если в качестве функции потерь взять квадратичную ошибку, то

$$H(R) = \min_{c \in \mathbb{R}} \frac{1}{|R|} \sum_{(x_i, y_i) \in R} (y_i - c)^2.$$

Ее минимум достигается при

$$c = \frac{1}{|R|} \sum_{(x_i, y_i) \in R} y_i,$$

то есть в листе предсказывается среднее значение целевой переменной на объектах, попавших в лист, поэтому

Критерии информативности

H(R) в задаче регрессии

Если в качестве функции потерь взять квадратичную ошибку, то

$$H(R) = \min_{c \in \mathbb{R}} \frac{1}{|R|} \sum_{(x_i, y_i) \in R} (y_i - c)^2.$$

Ее минимум достигается при

$$c = \frac{1}{|R|} \sum_{(x_i, y_i) \in R} y_i,$$

то есть в листе предсказывается среднее значение целевой переменной на объектах, попавших в лист, поэтому


Информативность H(R) в вершине дерева – это дисперсия целевой переменной (для объектов, попавших в вершину).

Чем меньше дисперсия, тем меньше разброс целевой переменной объектов, попавших в лист

Критерии информативности

Задача классификации


Предположим, что в лист дерева попало несколько объектов. В каждом листе дерево предсказывает класс объекта. Какой класс выгоднее всего выдать в качестве ответа?



Критерии информативности

Задача классификации

Предположим, что в лист дерева попало несколько объектов. В каждом листе дерево предсказывает класс объекта. Какой класс выгоднее всего выдать в качестве ответа?



Критерии информативности

$H(R)$ в задаче классификации

Решаем задачу классификации с K классами:
 $1, 2, \dots, K$.

Пусть p_k доля объектов класса k , попавших в вершину:

$$p_k = \frac{1}{|R|} \sum_{(x_i, y_i) \in R} [y_i = k]$$

Пусть k_* - самый представительный класс в данной вершине:

$$k_* = \operatorname{argmax}_k p_k$$

Информативность $H(R)$ в вершине дерева – это ошибка классификации:

$$H(R) = \min_{c \in Y} \frac{1}{|R|} \sum_{(x_i, y_i) \in R} [y_i \neq c]$$

Данный критерий является достаточно грубым, поскольку учитывает частоту p_{k_*} лишь одного класса

Критерии информативности

Критерий Джинни

В каждой вершине в качестве ответа будем выдавать не класс, а распределение вероятностей классов: $c = (c_1, \dots, c_K)$, $\sum_i c_i = 1$.

Качество распределения можно измерить с помощью **критерия Бриера**, измеряющего точность вероятностных прогнозов:

$$H(R) = \min_c \frac{1}{|R|} \sum_{(x_i, y_i) \in R} \sum_{k=1}^K (c_k - [y_i = k])^2$$

Можно показать, что оптимальный вектор вероятностей состоит из долей классов:
 $c_* = (p_1, \dots, p_K)$

Если подставить эти вероятности в исходный критерий информативности и провести ряд преобразований, то мы получим **критерий Джинни**: $H(R) = \sum_{k=1}^K p_k(1 - p_k)$

Критерии информативности

Энтропийный критерий

Запишем логарифм правдоподобия:

$$H(R) = \min_c \left(-\frac{1}{|R|} \sum_{(x_i, y_i) \in R} \sum_{k=1}^K [y_i = k] \log c_k \right) (*)$$

На векторе $c_* = (p_1, \dots, p_K)$ функционал (*) записывается в виде


$$H(R) = -\sum_{k=1}^K p_k \log p_k \text{ (энтропия)}$$

Энтропия $H(R) \geq 0$ (минимум на распределении $p_i = 1, p_j = 0, j \neq i$)

max H(R) достигается на равномерном распределении $p_1 = \dots = p_K = \frac{1}{K}$.


Критерии информативности

Энтропийный критерий (пример использования)



$$p_1 = \frac{9}{20}, p_2 = \frac{11}{20} \Rightarrow \text{энтропия } H_0 = -\frac{9}{20} \log \frac{9}{20} - \frac{11}{20} \log \frac{11}{20} \approx 1$$

Критерии информативности




Критерии останова

- Ограничение максимальной глубины дерева (`max_depth`)
- Ограничение минимального числа объектов в листьях (`min_samples_leaf`)
- Ограничение максимального числа листьев в дереве
- Останов в случае если все объекты в листе относятся к одному классу
- Требование, чтобы функционал качества при дроблении увеличивался как минимум на $s\%$.

Правильный подбор критерия существенно повышает качество, но затрачен и требует кросс-валидации.


Стрижка дерева (прунинг)

Альтернатива критериям останова: строится переобученное дерево (например, пока в каждом листе не окажется по одному объекту) и затем производится оптимизация структуры.



Стрижка дерева (прунинг)

Параметр прунинга — α — подбирается на кросс-валидации



Стрижка дерева (прунинг)

Стрижка позволяет достичь лучшего качества по сравнению с ранним остановом, но фактически используется редко и почти не реализована в большинстве библиотек, так как сами по себе деревья — это слабые алгоритмы и используются в основном только в более сложных моделях (случайных лесах, бустинге).

В первом случае они должны быть переобучены, во втором — должны иметь маленькую глубину и не требуют стрижки

Пример дерева

Ирисы Фишера



Плюсы деревьев

- Высокая степень интерпретируемости: хорошо визуализируются и имеют четкие понятные предикаты (например, «возраст > 25»)
- Быстро обучаются и выдают прогноз
- Имеют малое число параметров

Минусы деревьев

- Очень чувствительны к шумам в данных, модель сильно меняется при небольшом изменении обучающей выборки
- Разделяющая граница имеет свои ограничения (состоит из гиперплоскостей)
- Проблема поиска оптимального дерева (NP-полная задача, поэтому на практике используется жадное построение дерева)
- Необходимость борьбы с переобучением (стрижка или какой-либо из критериев останова)